
Rapport de stage:

Réalisation d'un Tableau de bord pour les données de mobilité en Transport en Commun

Tuteur école :

GEORGES SALAMEH
georges.salameh@ec-nantes.fr

Réviseur :

LUCAS LESTANDI
lucas.lestandi@ec-nantes.fr

Tuteur entreprise :

PIERRE MICHEL
pierre.michel@ifpen.fr

Auteur: Zihao GUO

August 26, 2022

CONTENTS

1	Remerciements	2
2	Introduction	3
2.1	Contexte du stage	3
2.2	Aperçu du stage	4
2.3	Objectifs du stage	4
3	Contexte technique et scientifique	5
3.1	Mobilité	5
3.2	Île-de-France Mobilités	5
3.3	Les transports commun à Paris	7
4	Contenu du stage	9
4.1	Partie 1. Nettoyage des données	9
4.2	Partie 2. Tableau de bord des données	16
4.3	Partie 3. Prediction	27
5	Perspectives et conclusions	51
5.1	Résumé du stage	51
5.2	Réflexions sur le stage	52
	Annexes	56
A	Annexe 1. Comparaison avec MATSIM et EGT	56
B	Annexe 2. Abréviations de mots	65

ABSTRACT

La promotion des transports publics est de plus en plus reconnue comme un outil important pour lutter contre les externalités liées à l'utilisation de la voiture (par exemple, la pollution locale et mondiale, la congestion, les accidents). Réduire les émissions de carbone en diminuant le coût des transports publics est donc une question de recherche urgente. Dans ce stage, nous avons construit un tableau de bord de données de validations des transports à Paris pour la période 2015-2021. Les résultats donnent lieu à des analyses de scénarios pour alimenter une étude plus générale des impacts environnementaux (gaz à effet de serre et émissions polluantes) des leviers à disposition des collectivités locales pour le report modal.

KEYWORDS Modélisation du transport et SIG, Modèles de séries chronologiques, Statistiques et mathématiques appliquées

1 REMERCIEMENTS

En ce moment, en regardant en arrière sur ces mois d'un stage épanouissant, chargé et heureux, je ressens beaucoup d'émotions. Ce voyage d'apprentissage inoubliable a été profond et enrichissant pour ma croissance et mon perfectionnement. Au moment de commencer mon rapport de stage, je tiens à exprimer mes remerciements les plus sincères à tous ceux qui m'ont aidé et soutenu.

Tout d'abord, je tiens à remercier mon superviseur, le **Dr. Pierre MICHEL**, pour son dévouement à tous les aspects de mon stage en plus de son calendrier de recherche chargé. Sans ses conseils avisés et son travail acharné, cette expérience de stage n'aurait pas été possible.

Au cours des cinq derniers mois, la conscience professionnelle, l'assiduité et l'ouverture d'esprit de M. MICHEL m'ont laissé une impression indélébile, des qualités que je m'efforcerai d'acquérir à l'avenir et qui constitueront pour moi un excellent exemple. En outre, je me souviendrai toujours des conseils professionnels du Dr. MICHEL et de son attention sans faille à mon égard. Je tiens à exprimer mon plus profond respect et ma gratitude à M. MICHEL.

Ensuite, je tiens à remercier **M. Alexandre LANVIN** pour sa manière souple d'aborder les problèmes, son approche rigoureuse de la résolution de problèmes et ses solides connaissances professionnelles, qui m'ont laissé une profonde impression. Les explications détaillées de M. LANVIN ont enrichi mes connaissances.

Je tiens à remercier **M. Georges SALAMEH** pour son soutien durant mes années d'études et pour son soutien durant mon stage. C'est grâce aux conseils et à l'aide de M. SALAMEH à différents moments que j'ai pu apprendre et développer mes compétences sans aucune distraction tout au long de l'année.

Je suis reconnaissant à **M. Alexandre CHASSE** pour son approche flexible des problèmes et sa rigueur dans la résolution des problèmes, qui m'a donné un sens de la rigueur dans mes études et qui sera pour moi un moteur et un repère pour continuer à avancer. Je tiens à exprimer mon plus profond respect à M. CHASSE.

Je tiens à remercier **M. Guoxi FENG** pour ses explications attentives et ses encouragements inlassables, qui m'ont permis de mener à bien mon stage et je tiens à lui exprimer ma sincère gratitude.

Je voudrais profiter de cette occasion pour exprimer ma profonde gratitude à tous les nombreux étudiants, amis et parents qui m'ont encouragé et aidé dans mes études. En plus de cela, je voudrais exprimer ma sincère gratitude aux auteurs des nombreuses études académiques que j'ai étudiées et citées au cours de la rédaction de mon rapport de stage.

Enfin, je tiens à exprimer ma profonde gratitude à tous les parents, enseignants et amis qui ont veillé sur moi. Avec l'amour que vous m'avez donné, je continuerai à avancer vers l'avenir.

2 INTRODUCTION

2.1 Contexte du stage

- Durée du stage: 04/04/2022 - 26/08/2022.
- Lieux de stage: 1-4 Av. du Bois Préau, 92852 Rueil-Malmaison.

2.1.1 Profil de l'entreprise^[1]

IFP Énergies nouvelles (IFPEN) est le successeur de l'Institut français du pétrole (IFP). Il est un acteur majeur de la recherche et de la formation dans les domaines de l'énergie, du transport et de l'environnement. De la recherche à l'industrie, l'innovation technologique est au cœur de son action.



Figure 1: IFP-Energies Nouvelles

Dans le cadre de la mission d'intérêt général confiée par les pouvoirs publics, IFPEN concentre ses efforts sur :

- l'apport de solutions aux défis sociétaux de l'énergie et du climat, en favorisant la transition vers une mobilité durable et l'émergence d'un mix énergétique plus diversifié ;
- la création de richesse et d'emplois, en soutenant l'activité économique française et européenne, et la compétitivité des filières industrielles associées.

IFPEN en chiffres (2021)

- **1 549** salariés (effectif total équivalent temps plein), dont 1 095 ingénieurs et techniciens en RI et 30 alternants
- Près de **150** allocataires de recherche, postdoctorants et stagiaires
- Plus de **50** métiers représentés
- **262,1 M€** de budget, dont **228 M€** pour la RI
- Un autofinancement à plus de **50%**
- **68%** du budget consacré aux nouvelles technologies de l'énergie
- **149** premiers dépôts de brevets dont 93 dans les NTE
- Plus de **600** publications scientifiques et communications à congrès
- **Plus de 70** projets de recherche collaboratifs en cours, dont près de 40 impliquant des partenaires étrangers

- Plus de 500 élèves diplômés par IFP School
- Plus de 30 entreprises créées par IFPEN depuis 1944

2.1.2 Profil de Tuteur[2]

Dr. Pierre MICHEL a obtenu en 2015 son doctorat à l'Université d'Orléans pour sa thèse sur la gestion d'énergie des véhicules hybrides. Après un post-doctorat à Argonne National Laboratory sur les véhicules connectés, il a participé au développement des chaînes de traction hybrides chez PSA Peugeot Citroën. Il a rejoint l'IFP Energies Nouvelles en 2019 et ses travaux de recherches s'intéressent à la modélisation énergétique des chaînes de traction, au développement d'algorithmes d'éco-conduite et plus généralement à l'analyse de la mobilité en utilisant la théorie du contrôle et la science des données.

2.2 Aperçu du stage

Paris est un bassin de vie d'environ 11 millions de personnes, composé d'un noyau dense d'environ 2 millions de personnes, la mairie de Paris étant entourée de banlieues. Selon les statistiques de 2010, près de 41 millions de déplacements sont effectués chaque jour à Paris, dont 20 % en transports publics[3]. Avec l'augmentation actuelle du prix des carburants et d'autres facteurs, l'utilisation des transports publics est appelée à augmenter à nouveau.

Ce stage se base sur un jeu de données open source fourni par IDFM[4], les validations des transports publics à Paris, et analyse ces données en construisant un tableau de bord de données afin de comprendre la situation des transports publics à Paris.

2.3 Objectifs du stage

1. Une analyse des données de validations des badges de transports. Cette analyse aura pour but de mettre en place un tableau de bord afin d'explorer les données.
2. Construire un modèle de série temporelle pour:
 - a) Calibrer les données de validation du RER 2018-2019.
 - b) Identifier l'impact des facteurs météorologiques et de vacances sur le flux de trafic.
3. Comparaison des données de validation avec les données obtenues à l'aide d'un modèle de transport basé sur les agents (MATSim) et avec les statistiques officielles (EGT).




Figure 2: Exemple : Comparaison des données statistiques avec les données de simulation MATSim

3 CONTEXTE TECHNIQUE ET SCIENTIFIQUE

3.1 Mobilité

La mobilité est la capacité de se déplacer ou d'être déplacé dans l'espace[5], et au sens le plus général, la mobilité est le changement de lieu par une ou plusieurs personnes. Toutefois, à une époque antérieure, la mobilité ne se limitait pas au mouvement physique réel (c'est-à-dire aux moyens de transport) ; elle englobait également l'idéologie et la technologie du mouvement dans la société[6].

Comme l'ont démontré Gabriel Dupuy[7] et Jacques Lévy[8]. La mobilité est définie comme "un concept global dont il faut écarter les notions qui entraînent une confusion dans le sens du mot mobilité, telles que : déplacement, transport, migration, etc. L'utilisation du terme "mobilité" est donc réservée au sens de "déplacement des personnes" et se définit comme "l'ensemble des pratiques de déplacement d'une population dans son cadre habituel"[9], puisque La mobilité est généralement considérée avant tout comme un déplacement quotidien.

3.2 Île-de-France Mobilités

Île-de-France Mobilités est l'Autorité Organisatrice de la mobilité durable en Ile-de-France[4]

- Île-de-France Mobilités imagine, organise et finance les transports publics pour tous les Franciliens. Chaque jour, ce sont plus de 10 millions de voyageurs qui empruntent le réseau de transport d'Île-de-France Mobilités, opéré par les 75 entreprises OPTILE, la RATP et la SNCF.




Figure 3: Plan du réseau de transport en commun en Île-de-France

- Chaque jour en Île-de-France 9,4 millions de déplacements sont réalisés par les Franciliens grâce à l'un des plus importants réseaux de transports en commun du monde. Que ce soit pour leurs déplacements professionnels ou pour leurs loisirs, équipés d'un passe Navigo (sur carte ou téléphone) ou d'un titre de transport occasionnel, les voyageurs peuvent emprunter les 1500 lignes de bus, 14 lignes de métros, 9 lignes de tramways et 13 lignes de trains et RER qui irriguent la Région. D'ici une dizaine d'années, le réseau d'Île-de-France Mobilités se sera enrichi des nombreux prolongements et des créations de métro, tram et RER en travaux en ce moment dont les prochaines lignes 15, 16, 17 et 18 du métro régional (projet Grand Paris Express).



(a) LOGO-IDFM

Transilien + RER	Métro	Tram et Tram-train	Bus
			
1 401 km	211 km	39 km	22 670 km (étendue)
444 gares	381 stations	67 arrêts	28 950 arrêts

(b) Types de transports publics à Paris

Figure 4: Informations sur Île-de-France Mobilités

- Le coût de fonctionnement de ce gigantesque système s'élève à plus de 10,5 milliards d'euros chaque année. Il est financé par les collectivités locales (Région, Départements et Ville de Paris), les employeurs via une taxe (le versement mobilité, anciennement versement transport) et via la prise en charge de 50% du coût de transport de leur personnel, et la vente des titres de transport. C'est Île-de-France Mobilités qui crée les différents titres de transports (Ticket t+, Navigo Liberté+, forfait Navigo, forfait Imagine'R, forfait Senior, forfait Junior etc. ...), et en fixe les tarifs.

Les opérateurs présents dans ces données sont la RATP et la SNCF.



(a) LOGO-RATP



(b) LOGO-SNCF

Figure 5: Logos des entreprises RATP et SNCF

- RATP

- La RATP est créée par la loi du 21 mars 1948, en remplacement de la Compagnie du chemin de fer métropolitain de Paris (CMP) et de la Société des transports en commun de la région parisienne (STCRP), afin de gérer l'ensemble des moyens de transport publics souterrains et de surface de Paris et de sa banlieue, qui étaient assurés par des entreprises privées jusqu'en 1944.
- La RATP exploite chaque jour huit modes de transport (métro, tramway, bus urbains et interurbains, trains régionaux, tourisme, navettes maritimes, transport à la demande et câble) et est présente dans de nouvelles chaînes de transport dans le cadre de partenariats (navettes autonomes, scooters électriques en libre-service, autopartage, parking intelligent et connecté).
- Depuis 2000, elle se développe en France et à l'étranger dans les marchés de l'exploitation de réseaux et de l'ingénierie en transport et est actuellement le cinquième acteur mondial du transport public.

- SNCF

- La Société nationale des chemins de fer français (SNCFNote 1) est l'entreprise ferroviaire publique française, officiellement créée par convention entre l'État et les compagnies de chemin de fer préexistantes, en application du décret-loi du 31 août 19375. Elle est notamment présente dans les domaines du transport de voyageurs, du transport de marchandises et réalise la gestion, l'exploitation et la maintenance du réseau ferré national appartenant à l'État.
- À partir du 1er janvier 2020, la SNCF devient une société anonyme dont le capital est détenu par l'État français. Elle est à la fois un opérateur (transport de passagers et de marchandises) et un gestionnaire de l'infrastructure ferroviaire.
- Chaque jour, la SNCF fait circuler en moyenne 15 000 trains commerciaux, achemine cinq millions de voyageurs et transporte 250 000 tonnes de marchandises. Par son volume d'activité et la taille de son réseau, c'est la troisième entreprise ferroviaire européenne, après la Deutsche Bahn et les Chemins de fer russes.

3.3 Les transports commun à Paris

1. L'Île-de-France

- La région parisienne (ou Île-de-France) est un vaste territoire de 12 011 kilomètres carrés et de 11,3 millions d'habitants.
- Comme le montre la carte ci-dessous [Fig. 6], la ville de Paris (ou Paris intra-muros) ne représente qu'une petite partie de la région, avec une superficie de 105 kilomètres carrés et 2,1 millions d'habitants.
- La banlieue de Paris est généralement divisée en deux parties : la "petite couronne", d'une superficie de 657 km² et de 4,2 millions d'habitants, et la "grande couronne", d'une superficie de 11 249 km² et de 5 millions d'habitants.




Figure 6: L'Île-de-France

2. La situation des transports à Paris

- En comparant la répartition du trafic entre 2010 et 2018 [Fig. 7(a)], nous pouvons tirer les conclusions présentées ci-dessous.
 - La croissance globale des déplacements en Île-de-France était estimée à + 7% en lien avec la croissance démographique.
 - Afin de réduire de 20% les émissions de gaz à effet de serre liées aux déplacements, il était nécessaire de réduire de 2% les déplacements en voiture et deux roues motorisés (selon les modélisations réalisés par Airparif en tenant compte des évolutions technologiques des motorisations).
 - Afin de compenser cette réduction, les déplacements réalisés par les autres modes devaient augmenter, augmentation fixée à parts égales en volume entre les transports collectifs et les modes actifs.
 - Ainsi, les déplacements en transports collectifs devaient continuer à croître de 20% entre 2010 et 2020 et les déplacements à pied et à vélo de 10
- Nous pouvons le constater en observant le graphique de l'évolution des flux de transport public [Fig. 7(b)].
 - Les années 70, 80 et 90 avaient été marquées par une stagnation des déplacements en transports collectifs autour de 6 millions par jour. La tendance est désormais toute autre.
 - La période 2010 – 2018 a poursuivi la tendance 2001 – 2010 en termes de croissance de l'usage des transports collectifs.





Figure 7: EGT H2020-Île-de-France Mobilités-OMNIL-DRIEA / Résultats partiels 2018[10]

4 CONTENU DU STAGE

4.1 Partie 1. Nettoyage des données

4.1.1 Présentation des données

1. Sources de données

- Depuis plusieurs années, Ile-de-France Mobilités[4] a décidé de généraliser le passage aux tickets magnétiques avec le Pass Navigo.
- Dans ce cadre, il a conçu un système d'information décisionnel lui permettant une meilleure connaissance de la mobilité des usagers. Ce système permet la remontée des données de validation depuis les opérateurs jusqu'à Ile-de-France Mobilités, puis leur uniformisation et leur archivage.



(a) Télébilléttique avec le Pass Navigo



(b) Schéma de la station de carte à puce

Figure 8: Présentation de la source de données, Image citée à partir de [4]

- Dès lors, à chaque fois qu'un usager valide son passe Navigo sur le réseau francilien, une information anonyme est remontée à un système central permettant la collecte et le calcul de statistiques sur la mobilité.

2. Règles de comptage des validations




Figure 9: Processus de remonté des données de validation

- Le processus de collecte et de traitement des données de validation est illustré dans [Fig. 9].
 - Les validations sont envoyées par les opérateurs à Ile-de-France Mobilités.
 - Ile-de-France Mobilités collecte, vérifie, nettoie et stock les données.
 - Ile-de-France Mobilités analyse les données pour comprendre la mobilité des franciliens.
 - Ile-de-France Mobilités met à disposition les données de validations en Open Data.




Figure 10: Illustration des règles

- Interprétation du diagramme
 - Les points blancs correspondent aux gares de départ et de destination, les points noirs correspondent aux autres gares.
- Pour les lignes ferroviaires
 - [Pour le métro et le train]:** Validation du badge à l'entrée de la station uniquement
 - [Pour le RER]:** La validation du badge est requise à l'entrée et à la sortie de la gare (également requise pour les transferts).
 - Remarque:** Pour les RER, les données sortantes ne sont pas comptabilisées dans l'ensemble de données. **Les données n'enregistrent que le nombre de fois où le badge a été validé à l'entrée.**
- Pour les lignes surface
 - [Pour le bus et le tram]:** L'enregistrement des validations à chaque embarquement signifie qu'il n'y a pas de données de validation pour une station particulière, mais seulement des données de validation pour différentes lignes.

3. Données de IDFM

- Informations sur la validation
 - Nombre de Validations de 2015 – 2021.(Ferré et Surface)
 - Ferré: Gares et stations du réseau ferré d'Île-de-France.
 - Surface: Lignes du réseau surface d'Île-de-France.
 - Profils horaires de 2015 – 2021.(Ferré et Surface)
- Informations de référence

- i. Référence des informations sur ligne
- ii. Référence des informations sur l'arrêt
- c) L'Enquête Globale Transport (2010)
- 4. Données simulées
 - a) Données simulées par MATSim

1.A EXEMPLE DES CINQ PREMIÈRES DONNÉES DE 2015

1. Nombre de Validations de réseau ferré

JOUR	CODE_STIF_TRNS	CODE_STIF_RES	CODE_STIF_ARRET
01/01/2015	100	110	1
01/01/2015	100	110	1
01/01/2015	100	110	1
01/01/2015	100	110	1
01/01/2015	100	110	1
LIBELLE_ARRET	ID_REFA_LDA	CATEGORIE_TITRE	NB_VALD
PORTE MAILLOT	71379	AMETHYSTE	117
PORTE MAILLOT	71379	AUTRE TITRE	37
PORTE MAILLOT	71379	FGT	172
PORTE MAILLOT	71379	IMAGINE R	605
PORTE MAILLOT	71379	NAVIGO	2039

* **JOUR**[Date]: Jour d'exploitation, **COD_STIF_TRNS**[Numérique]: Code Stif du transporteur, **COD_STIF_RES**[Numérique]: Code Stif du réseau, **COD_STIF_ARRET**[Numérique]: Code Stif de l'arrêt/ station, **LIBELLE_ARRET**[Caractère]: Libellé de l'arrêt/ station, **ID_REFA_LDA**[Caractère]: Identifiant arrêt référentiel STIF, **CATEGORIE_TITRE**[Caractère]: Titre de transport, **NB_VALD**[Numérique]: Nombre de validations (en entrée sur le réseau).

2. Nombre de Validations de réseau surface

JOUR	CODE_STIF_TRNS	CODE_STIF_RES	CODE_STIF_LIGNE
01/01/2015	2	2	3
01/01/2015	2	2	3
01/01/2015	2	2	3
01/01/2015	2	2	3
01/01/2015	2	2	3
LIBELLE_LIGNE	ID_GROUPOFLINES	CATEGORIE_TITRE	NB_VALD
Terminus	A00002	AMETHYSTE	170
Terminus	A00002	FGT	202
Terminus	A00002	IMAGINE R	162
Terminus	A00002	NAVIGO	321
Terminus	A00002	TST	157

* Terminus: CHOISY-LE-ROI (Gare RER) - VILLENEUVE-ST-GEORGES (VSG gare RER)

* **JOUR**[Date]: Jour d'exploitation, **COD_STIF_TRNS**[Numérique]: Code Stif du transporteur, **COD_STIF_RES**[Numérique]: Code Stif du réseau, **COD_STIF_LIGNE**[Numérique]: Code Stif de la ligne, **LIBELLE_LIGNE**[Caractère]: Libellé de la ligne, **ID_GroupOfLines**[Caractère]: Identifiant STIF de référence de la ligne administrative, **CATEGORIE_TITRE**[Caractère]: Titre de transport, **NB_VALD**[Numérique]: Nombre de validations (en entrée sur le réseau).

3. Profils horaires de réseau ferré

YEAR	CODE_STIF_TRNS	CODE_STIF_RES	CODE_STIF_ARRET	LIBELLE_ARRET
2015S1	100	110	1	PORTE MAILLOT
2015S1	100	110	1	PORTE MAILLOT
2015S1	100	110	1	PORTE MAILLOT
2015S1	100	110	1	PORTE MAILLOT
2015S1	100	110	1	PORTE MAILLOT
YEAR	ID_REFA_LDA	CAT_JOUR	TRNC_HORR_60	pourc_validations
2015S1	71379	DIJFP	0H-1H	1.96
2015S1	71379	DIJFP	10H-11H	4.01
2015S1	71379	DIJFP	11H-12H	4.43
2015S1	71379	DIJFP	12H-13H	5.36
2015S1	71379	DIJFP	13H-14H	5.53

* **COD_STIF_TRNS**[Numérique]: Code Stif du transporteur, **COD_STIF_RES**[Numérique]: Code Stif du réseau, **COD_STIF_ARRET**[Numérique]: Code Stif de l'arrêt/ station, **LIBELLE_ARRET**[Caractère]: Libellé de l'arrêt/ station, **ID_REFA_LDA**[Caractère]: Identifiant arrêt référentiel STIF, **CAT_JOUR**[Caractère]: Catégorie du jour, **TRNC_HORR_60**[Caractère]: Tranche horaire d'une heure, **POURC_VALIDATIONS**[Numérique]: Pour une station i : Rapport entre le nombre de validations à une station i, sur une tranche horaire TH, et le nombre de validations sur la journée entière à cette station i. Code Stif du réseau,

4. Profils horaires de réseau surface

YEAR	CODE_STIF_TRNS	CODE_STIF_RES	CODE_STIF_LIGNE	LIBELLE_LIGNE
2015S1	2	2	10	Terminus
2015S1	2	2	10	Terminus
2015S1	2	2	10	Terminus
2015S1	2	2	10	Terminus
2015S1	2	2	10	Terminus
YEAR	ID_GROUPOFLIGNE	CAT_JOUR	TRNC_HORR_60	pourc_validations
2015S1	A00006	JOHV	18H-19H	0.53
2015S1	A00006	JOHV	7H-8H	47.34
2015S1	A00006	JOHV	8H-9H	14.89
2015S1	A00006	JOHV	6H-7H	6.91
2015S1	A00006	JOHV	17H-18H	12.23

* Terminus: JUVISY-SUR-ORGE (R.E.R.) - ATHIS-MONS (Plaine Basse)

* **JOUR**[Date]: Jour d'exploitation, **COD_STIF_TRNS**[Numérique]: Code Stif du transporteur, **COD_STIF_RES**[Numérique]: Code Stif du réseau, **COD_STIF_LIGNE**[Numérique]: Code Stif de la ligne, **LIBELLE_LIGNE**[Caractère]: Libellé de la ligne, **ID_GroupOfLines**[Caractère]: Identifiant STIF de référence de la ligne administrative, **CAT_JOUR**[Caractère]: Catégorie du jour, **TRNC_HORR_60**[Caractère]: Tranche horaire d'une heure, **POURC_VALIDATIONS**[Numérique]: Pour une ligne j : Rapport entre le nombre de validations sur une ligne j, sur une tranche horaire TH, et le nombre de validations sur la journée entière sur cette ligne j.

1.B INFORMATIONS DE RÉFÉRENCE Les connexions entre les données sont indiquées ci-dessous.




Figure 11: Liens entre les données

4.1.2 Processus de nettoyage des données

1. Traitement de la base de données IDFM_Réseaux ferré

a) Informations sur la validation




Figure 12: Processus de traitement des données pour les nombre de validations des lignes ferroviaires

b) Informations sur le profil




Figure 13: Processus de traitement des données pour les profils de validations des lignes ferroviaires

2. Traitement de la base de données IDFM_Réseaux surface

a) Informations sur la validation




Figure 14: Processus de traitement des données pour le nombre de validations des lignes surface

b) Informations sur le profil




Figure 15: Processus de traitement des données pour les profils de validations des lignes surface

3. Traitement de la base de données IDFM_EGT




Figure 16: Processus de traitement des données pour EGT

4. Résumé du processus de traitement

a) Importation de données

b) Traitement de données

- Supprimer les valeurs vacantes (Par exemple, l'absence d'identifiants de ligne pour les lignes de surface)
- Fusionner les données de référence pour enrichir l'ensemble des données (Ajouter des informations sur les types de dates, les types de trafic, les régions, etc.)

c) [!] Symboles dans les organigrammes

- Smiley : le flux de données complet
- Drapeaux rouges : les données manquantes

4.2 Partie 2. Tableau de bord des données

4.2.1 Préparation des données MongoDB en back-end




Figure 17: Esquisse d'un tableau de bord de données

ÉTAPES (EXEMPLE DU DIAGRAMME À BARRES EN C)

1. Préparation des données
 - a) Importation des données de validation des réseaux ferrés nettoyées
 - b) Sélectionner le type de date comme jour ouvré
 - c) Données combinées par mois et par type de transport.
 - i. Prendre la moyenne du nombre de validations pour chaque mois
2. Générer des graphiques (Basé sur plotly)
3. Dépôt des données dans la base de données
 - a) Connexion à la base de données

```
import pymongo
from pymongo import MongoClient

client = MongoClient("mongodb://localhost:27017/")
db = client["IDFMOpenData"]
```

- b) Dépôt dans la base de données


```
df_image = df_image.reset_index().drop(columns = {'index'})
db.nom_dans_mongoDB.insert_many(json.loads(df_image.T.to_json()).values())
```

4.2.2 Conception de tableaux de bord de données sur le front-end

EXEMPLE DU DIAGRAMME À BARRES EN C

1. Construction de cadres web à l'aide des langages html et css

- Conception de l'en-tête et du pied de page
- Utiliser la mise en page flexbox pour obtenir la mise en page du cadre dans l'ébauche



Analyse des données open-data IDFM

Des données de badgeages de réseaux surface

Des données de badgeages de ▾

Nom du développeur: P. Michel, Z. Guo

(a) En-tête de page




(b) Bas de la page



Analyse des données open-data IDFM

Nom du développeur: P. Michel, Z. Guo

Toutes les données Données annuelles Données mensuelles



(c) Cadre Web

Figure 18: Conception de la mise en page du site Web

2. Générer des graphiques sur la page

- a) Obtenir des données de la base de données
- b) Emballage des images en tant que classes
- c) Valeur de retour passée au frontal (tableaux de bord)


3. Ajouter des hyperliens et embellir la page

Analyse des données open-data IDFM

Des données de badgeages de réseaux ferrés

Nom du développeur: P. Michel, Z. Guo

Toutes les données Données annuelles Données mensuelles




(a) Réseaux ferré TB_1

Analyse des données open-data IDFM

Des données de badgeages de réseaux ferrés

Nom du développeur: P. Michel, Z. Guo

Toutes les données Données annuelles Données mensuelles




(b) Réseaux ferré TB_2

Analyse des données open-data IDFM


Des données de badgeages de réseaux ferrés

Nom du développeur: P. Michel, Z. Guo

Toutes les données Données annuelles Données mensuelles



(c) Réseaux ferré TB_3



(d) Réseaux surface TB

Figure 19: L'aspect final du tableau de bord des données

4.2.3 l'analyse de chaque graphique

1. Tableau de bord des données pour réseaux ferrés

a) Pour toutes les données [Fig. 19(a)]



(a) Par mois



(b) Par semaine

Figure 20: Tableau de bord des données pour réseaux ferrés toutes les données

i. Pour la figure 1

- A. Montre des informations sur le réseau ferrés pour faciliter la compréhension du contenu des données.
- ii. Pour la figure 2
 - A. Montre la répartition du nombre de validations par année, département et type de transport.
 - B. Selon l'année : La période de fermeture de l'épidémie en 2020 a donné lieu au plus faible pourcentage de validations, 2021 était encore dans la période de récupération post-épidémique et avait le deuxième pourcentage le plus élevé, 2015-2019 avait un pourcentage relativement proche, mais 2019 avait le pourcentage le plus élevé.
 - C. Selon le département :
 - 1. **[Description du phénomène]** Le 75 avait la plus grande proportion de validations toutes années confondues, suivi du 92, mais le 93 avait une plus grande proportion de validations que le 92 en 2020, année de la mise en quarantaine.
 - 2. **[Analyse globale]** Ce rapport est logique, puisque la carte des transports de Paris[11] montre que le département 75 possède un réseau de transport plus dense, suivi du département 92.
 - 3. **[Analyse pour 2020]** La Défense dans le 92ème département est le centre économique de Paris et compte de nombreux travailleurs qui ont besoin de travailler. Pour 2020, de nombreux travailleurs choisissent de travailler en ligne, donc le nombre de déplacements à La Défense diminue, ce qui entraîne un changement dans le nombre de validations.
 - D. Selon le type de transport :
 - 1. **[Description du phénomène]** Les lignes de métro ont la plus grande part dans les provinces 75 et 92, le train a la plus grande part dans les provinces 78 et 95, et le reste des provinces (93, 94, 91, 77) ont toutes la plus grande part de RER
 - 2. **[Analyse]** Ce phénomène découle de la classification des réseaux ferrés de Paris : pour les zones urbaines : métro, pour les banlieues : RER, pour les banlieues éloignées : train, par exemple pour les départements 78 et 95, qui sont des banlieues éloignées de Paris et ne disposent pas de métro, et sont donc plus fréquemment desservies par le train. Cette situation garantit que le trafic du réseaux ferrés parisien est utilisé de manière à minimiser le gaspillage des ressources de transport.
- iii. Pour la figure 3
 - A. Les différentes périodes sont indiquées par la couleur du diagramme à barres : rose : vacances d'été, vert : vacances d'hiver, jaune : après l'épidémie, rouge : pendant la fermeture.
 - B. On constate que la période ayant le plus grand impact sur le flux de passagers est la période de fermeture, mais cette période est due à des facteurs incontrôlables
 - C. Pour les périodes de vacances d'été et d'hiver, la réduction de la fréquentation est plus prononcée et, par conséquent, une partie du trafic peut être réduite pendant la période de vacances.
 - D. Nous pouvons observer qu'après l'épidémie de 2020, la diminution du trafic de vacances est proche de 10% par rapport à la période pré-2020, ce qui peut être considéré comme étant dû à un désir réduit de voyager en raison de l'épidémie.
- b) Pour les données annuelles [Fig. 19(b)]




Figure 21: Tableau de bord des données pour réseaux ferrés toutes les données

i. Pour la figure 1

A. Par département, Nous pouvons voir que chaque zone a des heures de pointe différentes.

- Pour la pointe du matin, toutes les provinces sont 7-8H ou 8-9H, sauf la province 93 qui est 7-9H.
- Pour le pic du soir, pour les départements 75 et 92, il est de 17-19H ; les autres sont de 17-18H.
- Nous pouvons constater que les débits de pointe du matin et du soir sont à peu près les mêmes dans la province 75, tandis que toutes les autres provinces ont plus de débits de pointe du matin que de débits de pointe du soir.
- **[Analyse]** Nous pouvons optimiser le nombre de trajets en fonction de l'heure et des conditions de la période de pointe. Par exemple, pour les heures de pointe du soir, les heures de pointe plus longues dans les provinces 75 et 92 signifient que ces deux départements ont une population plus importante et doivent organiser le plus grand nombre possible de déplacements pour les transports.

B. Par mode

- On peut voir que la pointe du soir pour le type métro est une heure plus tard que les autres types, tandis que les débits de pointe du matin et du soir sont presque identiques, tous les autres types ayant des débits de pointe du matin plus importants que ceux du soir.

C. **[Analyse]** Nous pouvons augmenter ou diminuer le nombre de trains en fonction du flux de trafic à chaque heure de la journée pour différents types de trafic afin d'éviter les embouteillages et la congestion des gares.

ii. Pour la figure 2 (2018 en tant qu'exemple)

- A. Sur la carte, chaque point représente une plate-forme et le nombre de personnes vérifiées peut être déterminé par le changement de couleur et la taille du point.
- B. Comme le montre la carte, la station dont la couleur est la plus foncée (la plus proche du rouge) est La Défense. Ce résultat est illustré dans le nuage de points ci-dessous.

- C. Le nuage de points indique le nom des cinq stations ayant le nombre moyen de validations le plus élevé et le nombre de validations pour l'année sélectionnée (par exemple, pour 2018).
- iii. Pour la figure 3 (2018 en tant qu'exemple)
- A. Nous pouvons voir le pourcentage de validations pour différentes lignes de différents types de trafic pour chaque mois de l'année sélectionnée.
- B. Pour chaque mois le pourcentage du nombre de validations
1. **[Description du phénomène]** On constate que le mois où le nombre de validations est le plus élevé est le mois de janvier et que le mois où le nombre de validations est le plus faible est le mois d'août, un phénomène qui va dans le sens du phénomène précédent de diminution du nombre de vacances d'été.
 2. **[Analyse]** Nous pouvons en déduire que le taux d'occupation était relativement faible en août et qu'il n'y avait pas beaucoup de passagers.
- C. Pour chaque type de transport et de ligne le pourcentage du nombre de validations
1. **[Description du phénomène]** Quel que soit le mois, le métro représente plus que les deux autres, et si l'on prend l'exemple du mois de janvier, on constate que la part la plus importante revient à la ligne 12 du métro et la part minimale est de Train R.
 2. **[Analyse]** Nous pouvons en déduire que le taux d'occupation du TRAIN R est relativement faible à ce moment-là et qu'il n'y a pas beaucoup de passagers à bord.
- c) Pour les données mensuelles [Fig. 19(c)]




Figure 22: Tableau de bord des données pour réseaux ferrés_Les données mensuelles

- Pour la figure 1
 - La figure 1 montre la part de chaque type de trafic au cours des différents mois.
 - Pour la figure 2
 - Comme on peut le voir sur la figure 2, on peut identifier les stations ayant un nombre élevé de validations.
 - Cela peut être utilisé pour ajuster la distribution du trafic, par exemple en agrandissant ces stations ou en augmentant le volume de trafic à cette station pour soulager la pression sur le trafic piéton.
2. Tableau de bord des données pour réseaux surfaces
- Pour toutes les données [Fig. 19(d)]



Figure 23: Tableau de bord des données pour réseaux Surface

i. Pour la figure 1

A. Nous pouvons voir le pourcentage du nombre de validations par année, 2019 étant la plus importante et 2020 la moins importante, un phénomène similaire aux réseaux ferrés.

ii. Pour la figure 2

A. Nous pouvons constater une plus petite variation de la fréquentation pendant les vacances sur les réseaux surface avant et après l'épidémie que sur réseaux ferrés.

B. La variation par rapport à la période pré-épidémique est inférieure à 10% pendant les vacances d'été, alors qu'elle est plus importante en hiver, lorsque le nombre de personnes se déplaçant pendant les vacances est plus élevé que d'habitude.

iii. Pour la figure 4

A. Nous pouvons conclure que l'heure de pointe du trafic pour les bus est une heure plus tôt que l'heure de pointe du trafic pour les trams.

B. Les trams ont à peu près les mêmes débits de pointe le matin et le soir, les bus ont plus de débits de pointe le matin que le soir.

C. [Analyse] Nous pouvons augmenter ou diminuer le nombre de trains en fonction du flux de trafic à chaque heure de la journée pour différents types de trafic afin d'éviter les embouteillages et la congestion des gares.

4.2.4 Problèmes rencontrés et solutions


1. Calcul de la moyenne du nombre de validations

- Remarque:** Groupby[12] est une fonction de Pandas qui consiste à diviser des objets, à appliquer des fonctions et à fusionner certaines combinaisons de résultats. Cela peut être utilisé pour regrouper une grande quantité de données et effectuer des opérations de calcul sur ces groupes.
- Méthode 1:** Utiliser Groupby.mean pour trouver la moyenne.
- Méthode 2:** Utiliser Groupby.sum pour trouver la somme et divisez par le nombre de jours pour obtenir la moyenne.


Définir: $V(g, j)$: le nombre de validations, avec g : Nombre de gares et j : Nombre de jours

a) **Méthode 1:** $\overline{V(g, j)}$, En fait, c'est $\frac{\sum V(g, j)}{g}$


b) **Méthode 2:** $\frac{\sum V(g, j)}{j}$



(a) Nombre de validations à chaque station




(b) Méthode 1




(c) Méthode 2

Figure 24: Les différentes méthodes de calcul de la moyenne ont donné des résultats incohérents.

Dans ce graphique [Fig. 24], on peut voir que la station avec le plus grand nombre de valideurs est La Défense, d'après la couleur et la taille de la dispersion, mais la station avec le plus grand nombre de valideurs à gauche est Saint-lazare. Selon l'étude, il a été constaté que les résultats incohérents étaient dus à des incohérences dans la dimensionnalité de la moyenne. Voici un exemple de graphique des changements départements [Fig. 25], qui sera expliqué.



(a) Case.1_Méthode 1



(b) Case.2_Méthode 2

Figure 25: Les différentes méthodes de calcul de la moyenne exemple

- Prenons l'exemple de 2015, On peut trouver, les deux méthodes de calcul de la moyenne donnent des valeurs différentes

Table 1: Comparaison des deux scénarios

Département	NB_ARR	NB_VAL	MC1	MC2
Dept_75	412272	723884452	1756	2864438
Dept_77	96578	33939379	51	134299
Dept_78	110787	47224602	426	186870
Dept_91	98157	35814560	365	141720
Dept_92	98962	150094741	1517	593931
Dept_93	86182	117456507	1363	464780
Dept_94	76507	92291793	1206	365202
Dept_95	92960	37505536	403	148411

* NB_ARR: Nombre de stations, NB_VAL: Nombre de badges de vérification, MC1: Valeurs obtenues en utilisant la première méthode de calcul, MC2: Valeurs obtenues en utilisant la deuxième méthode de calcul

- Pour le case 1, étant donné qu’il n’y a aucune garantie que le nombre total de stations dans le département est le même pour chaque station, la valeur moyenne est calculée même s’il n’y a qu’un seul nombre de validation dans une station, de sorte que la valeur résultante n’est pas précise.
- Pour le case 2, nous le calculons en termes de jours, car le nombre de jours ouvrables par an est approximativement le même et la moyenne est donc plus significative.
- On utilise donc la méthode 2 qui consiste à faire la moyenne des sommes en divisant par le nombre de jours.

2. Anomalies du nombre de validations du RER en 2018-2019

- a) En regardant le graphique de tendance pour les lignes de fer [Fig. 26], nous voyons que pour les lignes ferroviaires, la tendance des données entre 2018 et 2019 n’est pas normale.




Figure 26: Carte des tendances des lignes de fer

- b) En regardant les diagrammes à barres [Fig. 27] pour les différents types, nous pouvons voir que les types de RER S2 pour 2018 et 2019 ont changé de manière significative par rapport à 2017 et S1 pour les deux années, ce qui suggère initialement que les types de RER créent des problèmes.




Figure 27: Les différents types de tendances

- c) Par la suite, nous avons examiné les données de 2018 et 2019 pour tenter de trouver les raisons.
- Le type de ticket est vérifié afin d'identifier ultérieurement les données manquantes dues à l'absence d'un certain type de ticket.




Figure 28: Graphique de tendance du RERA

- Aucun type de ticket n'a été trouvé manquant.
- Les types de RER ont ensuite été testés séparément pour TRAIN, METRO et TRAM (T4), et il s'est avéré que le type de RER présentait des problèmes. Parmi ceux-ci, les questions RERA et RERB sont évidentes.[En utilisant les tendances de 2017 comme référence]




Figure 29: Tendances de validation pour RERA et RERB.

- d) Une comparaison des stations a révélé deux problèmes

- Statistiques des doublons pour S1 2019.
- Données S2 manquantes pour 2018 et 2019.




Figure 30: Exemples de questions pour 2018-2019

Table 2: Top 8 avec l'erreur absolue la plus importante

Informations sur les transports		Année des données de validation						
		2015	2016	2017	2018 S1	2018 S2	2019 S1	2019 S2
Lignes	Stations							
RER A	LA DEFENSE-GRANDE ARCHE	C	C	C	Fev: Po	Po	C	Po
	GARE DE LYON	C	C	C	Fev: Po	Po	P2	Po
	CHATELET-LES HALLES	C	C	C	Avr: Po	P1	P2	Po
	CHARLES DE GAULLE ETOILE	C	C	C	C	C	P2	P2
	AUBER	C	C	C	Avr: Po	C	P2	P2
	NATION	C	C	C	C	Po	P2	Po
RER B	DENFERT-ROCHEREAU	C	C	C	Avr: Po	C	P2	P2
RER C	BIBLIOTHEQUE FRANCOIS MITTERRAND	C	C	C	C	C	P2	C

* C: Relativement normal, Po: Données manquantes, P1: Pas de données, P2: Trop de données.

e) Nous avons donc choisi un moyen de corriger les données de validation pour le RER 2018-2019, dont les étapes détaillées sont décrites dans la section suivante.

4.3 Partie 3. Prediction

4.3.1 Connaissances de base

1. **Prévision de séries chronologiques** En termes simples, une série chronologique est un ensemble de variables aléatoires ordonnées dans le temps, généralement le résultat d'observations d'un processus potentiel à un taux d'échantillonnage donné sur des périodes de temps équidistantes. Actuellement, La modélisation des séries chronologiques est devenue une partie intégrante des applications dans presque tous les domaines, tels que la modélisation du climat[13], les biosciences[14], le commerce[15] et la finance.[16]

Les méthodes traditionnelles de prévision des séries temporelles reposent sur des connaissances spécialisées, telles que les modèles autorégressifs (AR)[17], de lissage exponentiel[18] ou de séries temporelles structurées[19], où les paramètres du modèle sont résolus sur la base d'un modèle paramétrique de séries temporelles et le modèle résultant est utilisé pour compléter la prévision.

Avec l'augmentation récente de la disponibilité des données et de la puissance de calcul, et le lien étroit entre le travail de prévision des données de séries chronologiques et essentiellement l'analyse de régression dans la classification des méthodes d'apprentissage automatique, les machines à vecteurs de support classiques SVM[20], les réseaux bayésiens BN[21] et les processus gaussiens GP[22] ont tous obtenu de bons résultats dans la prédiction des séries chronologiques.

Les premiers réseaux neuronaux artificiels (ANN) ont également été utilisés[23] pour obtenir des tendances dans les séries chronologiques sur de longues périodes. L'étude de Lim et. al.[24] montre clairement que les réseaux neuronaux profonds permettent non seulement d'éviter la conception de modèles[25], mais aussi de simplifier le processus de formation du réseau[26]. Avec l'essor de l'apprentissage profond, ce domaine est devenu un élément important de la prochaine génération de modèles de prévision des séries chronologiques.




Figure 31: Modèles de séries chronologiques

2. Introduction du modèle

a) Modèles de régression linéaire

- La régression linéaire est une méthode de modélisation de la relation entre une ou plusieurs variables indépendantes.
- L'objectif de la régression linéaire est de trouver une ligne droite et de faire en sorte que cette ligne corresponde le mieux possible aux points de données du graphique.
- Prenons l'exemple d'une régression linéaire unidimensionnelle.

$$y_0 = \beta_0 + \beta_1 x + \mu \quad (1)$$

- i. μ représente la différence entre la théorie et la pratique, également appelée "erreur".

b) Modèles d'auto-Regressive Integrated Moving Average

ARIMAX MODEL: L'acronyme ARIMA signifie "Auto-Regressive Integrated Moving Average" (moyenne mobile intégrée auto-régressive) et, dans cet article, nous allons le décomposer en AR, I et MA.

Definition 1 (Autoregressive Component — AR(p)). La composante autorégressive du modèle ARIMA est représentée par AR(p), le paramètre p déterminant le nombre de séries retardées que nous utilisons.

$$y_t = c + \sum_{i=1}^p \alpha_i y_{t-i} + \varepsilon_t \quad (2)$$

Definition 2 (Moving Average — MA(q)). MA(q) est le modèle de moyenne mobile et q est le nombre de termes d'erreur de prévision décalés dans la prédiction. Dans un modèle MA(1), notre prévision est un terme constant plus le terme de bruit blanc précédent multiplié par un multiplicateur, ajouté au terme de bruit blanc actuel. Il s'agit d'une simple probabilité + statistique, car nous ajustons notre prévision en fonction des termes de bruit blanc précédents.

Definition 3 (ARMA). Le modèle ARMA est une constante plus la somme des retards AR et leurs multiplicateurs, plus la somme des retards MA et leurs multiplicateurs plus un bruit blanc. Cette équation est la base de tous les modèles suivants et constitue un cadre pour de nombreux modèles de prévision dans différents domaines.

Definition 4 (ARIMA). Le modèle ARIMA est un modèle ARMA mais avec une étape de pré-traitement incluse dans le modèle que nous représentons par I(d). I(d) est l'ordre de différence, c'est-à-dire le nombre de transformations nécessaires pour rendre les données stationnaires. Ainsi, un modèle ARIMA est simplement un modèle ARMA sur la série temporelle différenciée.

$$y_t = \beta_2 + \omega_1 \varepsilon_{t-1} + \omega_2 \varepsilon_{t-2} \dots + \omega_q \varepsilon_{t-q} + \varepsilon_t \quad (3)$$

Definition 5 (SARIMA). Le modèle ARIMA est excellent, mais inclure la saisonnalité et les variables exogènes dans le modèle peut être extrêmement puissant. Comme le modèle ARIMA suppose que la série temporelle est stationnaire, nous devons utiliser un modèle différent.

$$y_t = c + \sum_{i=1}^p \alpha_i y_{t-i} + \sum_{i=1}^q \theta_i \varepsilon_{t-i} + \sum_{i=1}^P \phi_i y_{t-s-i} + \sum_{i=1}^Q \eta_i \varepsilon_{t-s-i} + \varepsilon_t \quad (4)$$

- Entrez dans le modèle SARIMA (Seasonal ARIMA). Ce modèle est très similaire au modèle ARIMA, sauf qu'il y a un ensemble supplémentaire de composantes autorégressives et de moyennes mobiles. Les retards supplémentaires sont compensés par la fréquence de la saisonnalité (ex. 12 - mensuel, 24 - horaire).
- Les modèles SARIMA permettent de différencier les données selon la fréquence saisonnière, mais aussi selon la fréquence non saisonnière. La connaissance des meilleurs paramètres peut être facilitée par des cadres de recherche automatique de paramètres tels que pmdarina.

Definition 6 (ARIMAX/ SARIMAX).

$$y_t = c + \sum_{i=1}^p \alpha_i y_{t-i} + \sum_{i=1}^q \theta_i \varepsilon_{t-i} + \sum_{i=1}^r \beta_i x_{n_t} + \sum_{i=1}^P \phi_i y_{t-s-i} + \sum_{i=1}^Q \eta_i \varepsilon_{t-s-i} + \varepsilon_t \quad (5)$$

Ci-dessus se trouve le modèle SARIMAX. Ce modèle prend en compte les variables exogènes, ou en d'autres termes, utilise des données externes dans nos prévisions. Parmi les exemples réels de variables exogènes, citons le prix de l'or, le prix du pétrole, la température extérieure, le taux de change.

Il est intéressant de penser que tous les facteurs exogènes sont encore techniquement modélisés indirectement dans la prévision du modèle historique. Cela dit, si nous incluons des données externes, le modèle réagira beaucoup plus rapidement à leur effet que si nous nous fions à l'influence des termes retardés.

c) Modèles de Prophet

i. Informations de base

- fbprophet est un algorithme de prédiction de séries temporelles mis à disposition par Facebook, qui convient aux données présentant des modèles intrinsèques évidents.
- Décrit dans le document du Prophet[27], il s'agit d'un soi-disant: modèle de série chronologique décomposable avec 3 composantes principales du modèle : tendance, saisonnalité et vacances.

ii. Introduction au principe

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t \quad (6)$$

- $g(t)$ désigne le terme de tendance, qui représente la tendance de la série chronologique sur la non-période.
- $s(t)$ désigne le terme de période, ou terme saisonnier, qui est généralement mesuré en semaines ou en années.
- $h(t)$ désigne le terme de vacances, qui représente l'effet sur les valeurs prédites des vacances potentielles dans la série chronologique qui a une période non fixe. Cet élément peut également être appelé "variable externe".
- ϵ_t , le terme d'erreur ou terme résiduel, représente les fluctuations non prédites par le modèle, ϵ_t suit une distribution gaussienne.

d) Modèles de Neuralprophet

i. Informations de base

- NeuralProphet est un outil de prévision des séries temporelles convivial basé sur une implémentation PyTorch qui reprend les principales caractéristiques de l'outil de prévision open source de Facebook de 2018, Prophet, et est principalement utilisé pour l'analyse des données de séries temporelles.
- Il présente les deux principaux changements suivants par rapport au prophet:
 - Le composant de décomposition ajoute un AR (autorégressif) pondéré.

ii. Introduction au principe

$$y(t) = T(t) + S(t) + E(t) + F(t) + A(t) + L(t) \quad (7)$$

- $T(t)$ = tendance au moment t
- $S(t)$ = effet saisonnier au moment t
- $E(t)$ = effets de l'événement et des vacances au moment t
- $F(t)$ = effet de régression des variables exogènes futures connues au moment t
- $A(t)$ = effet autorégressif basé sur les observations passées au temps t
- $L(t)$ = effet de régression des observations retardées des variables exogènes au temps

Tous les modules composant le modèle peuvent être configurés individuellement et combinés pour constituer le modèle. Si tous les modules sont désactivés, un seul paramètre de décalage statique est installé comme composant de tendance. Par défaut, seuls les modules de tendance et de saisonnalité sont activés.

iii. NeuralProphet est un modèle de série chronologique décomposable dont les composantes sont similaires à celles de FBProphet, telles que la tendance, la saisonnalité, l'autorégression et les événements spéciaux, mais qui diffère par l'introduction de régresseurs futurs et de régresseurs retardés.

- Les termes de régression futurs sont des variables externes dont les valeurs futures sont connues pour la période de prévision.

- Les termes de régression décalés sont les variables externes pour lesquelles seules les valeurs de la période observée sont disponibles.
 - La tendance peut être modélisée de façon linéaire ou en combinant plusieurs tendances linéaires en fixant des points de changement.
 - Saisonnalité La saisonnalité est modélisée à l'aide de termes de Fourier, de sorte que des saisonnalités multiples peuvent être traitées pour les données à haute fréquence.
 - Le terme d'autorégression est traité à l'aide d'une implémentation de AR-Net[28], un réseau neuronal autorégressif de type Feed-Forward pour les séries temporelles.
- iv. Dans le package neuralprophet, il existe trois méthodes de prédiction pour les données situées en dehors de l'ensemble de données de prédiction[29].
- A. Recueillir des prévisions hors échantillon, c'est-à-dire étendre les prévisions à des futurs inconnus.
 - B. Prédiction sur la base d'objectifs prévisionnels.
 - C. Prévisions basées sur le début des prévisions.

3. Métriques d'évaluation[30]

Au cours de ce stage, la performance prédictive du modèle est évaluée sur la base de MAE, MAPE et R^2 .

a) Indicateurs de vérification des erreurs

INTRODUCTION AU PRINCIPE Il existe de nombreuses mesures qui peuvent être utilisées pour analyser la performance de notre prédiction. Nous utiliserons donc les 3 mesures les plus utilisées pour la prévision des séries temporelles. Chacune de ces métriques est différente des autres par la manière dont elle teste nos prédictions. Il ne faut donc pas s'attendre à ce qu'un modèle soit le plus performant dans toutes les métriques. Choisir la bonne métrique pour votre problème est également un grand défi, cela dépendra de vos besoins de prévision.

- Mean Absolute Error (MAE)[31]

En statistique, l'erreur absolue moyenne (EAM) est une mesure des erreurs entre des observations appariées exprimant le même phénomène. Les exemples de Y par rapport à X comprennent les comparaisons entre les prévisions et les observations, le temps ultérieur et le temps initial, et une technique de mesure par rapport à une autre technique de mesure. La MAE est calculée comme la somme des erreurs absolues divisée par la taille de l'échantillon

$$MAE = \frac{\sum_{i=1}^n |y_i - x_i|}{n} = \frac{\sum_{i=1}^n |e_i|}{n} \quad (8)$$

- Mean Absolute Percentage Error (MAPE)

L'erreur absolue moyenne en pourcentage (MAPE), également appelée écart absolu moyen en pourcentage (MAPD), est une mesure de la précision de la prévision d'une méthode de prévision en statistique. Elle exprime généralement la précision sous la forme d'un ratio défini par la formule :

$$MAPE = \frac{100\%}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right| \quad (9)$$

where A_t is the actual value and F_t is the forecast value.

- R2 Coefficient of determination (r^2)[32]

En statistique, le coefficient de détermination, noté R^2 ou r^2 et prononcé "R au carré", est la proportion de la variation de la variable dépendante qui est prévisible à partir de la ou des

variables indépendantes.

Si $\bar{y}$ est la moyenne des données observées :

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

Alors la variabilité de l'ensemble des données peut être mesurée à l'aide de deux formules de somme des carrés : La somme des carrés des résidus, également appelée somme des carrés des résidus :

$$SS_{\text{tot}} = \sum_i (y_i - \bar{y})^2$$

La somme totale des carrés (proportionnelle à la variance des données) :

$$SS_{\text{res}} = \sum_i (y_i - f_i)^2 = \sum_i e_i^2$$

La définition la plus générale du coefficient de détermination est la suivante

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} \quad (10)$$

En général, un R-carré plus grand indique un meilleur ajustement du modèle. Si le résultat est 0, le modèle est mal ajusté. Si le résultat est 1, le modèle est sans erreur.

b) Critères optimaux de sélection des modèles

AIC[33] Le critère AIC a été proposé par le statisticien japonais Akaike en 1973 et est connu sous le nom de critère d'information d'Akaike (critère de minimisation). Il s'agit d'une fonction pondérée de la précision de l'ajustement et du nombre de paramètres. Supposons que nous ayons un modèle statistique des données. Soit Les valeurs AIC du modèle sont alors les suivantes.

$$AIC = 2k - 2\ln(\hat{L}) \quad (11)$$

Où k est le nombre de paramètres estimés dans le modèle, $\hat{L}$ est la valeur maximale de la fonction de vraisemblance du modèle.

BIC[34] En statistique, le critère d'information bayésien (BIC) ou critère d'information de Schwartz (également connu sous le nom de SIC, SBC, SBIC) est le critère de sélection des modèles dans un ensemble fini de modèles ; le modèle ayant le BIC le plus faible est généralement préféré. Il est basé en partie sur la fonction de vraisemblance et est étroitement lié au critère d'information d'Akaike (AIC).

$$BIC = k\ln(n) - 2\ln(\hat{L}) \quad (12)$$

Où n est la taille de l'échantillon des données observées.

HQC[35] En statistique, le critère d'information de Hannan-Quinn (HQC) est un critère de sélection de modèles. Il est une alternative au critère d'information d'Akaike (AIC) et au critère d'information bayésien (BIC). Il est donné comme suit:

$$HQC = -2L_{\max} + 2k\ln(\ln(n)) \quad (13)$$

Où $L_{\max}$ est la log-vraisemblance, k est le nombre de paramètres, et n est le nombre d'observations.

RÉSUMÉ De toute évidence, plus ces trois paramètres d'évaluation sont petits, mieux c'est. Nous déterminons le modèle le plus optimal (p , q) pour AIC, BIC par recherche sur grille.

4. Méthodes d'évaluation des modèles

a) Méthodologie des prévisions glissantes

INTRODUCTION AU PRINCIPE Certaines méthodes typiques utilisées pour les travaux de prévision des séries temporelles, telles que arima, ets, doivent tenir compte de l'autocorrélation potentielle des séries temporelles lors des tests croisés, c'est-à-dire que la distribution identique indépendante des observations ne peut être satisfaite, sans parler du fait que la modélisation des séries temporelles doit prendre en compte le fait que les propriétés statistiques des séries temporelles sont strictement lisses.

Par conséquent, lorsqu'il s'agit de tests croisés pour la prévision des séries chronologiques, une méthode spéciale de tests croisés est nécessaire - la validation croisée par blocs mobiles[36].

- i. À partir d'une série temporelle de longueur m , la première à la n ième observation est considérée comme l'ensemble d'apprentissage et la n ième+1ième observation comme l'ensemble de test, et l'erreur de prédiction est calculée en faisant correspondre le modèle de l'ensemble d'apprentissage à l'ensemble de test.
- ii. Après avoir effectué les étapes ci-dessus, l'ensemble d'apprentissage et l'ensemble de test sont avancés d'une observation, et les étapes ci-dessus sont répétées jusqu'à ce que la n ième observation de la série temporelle soit également prise par l'ensemble de test, puis le cycle se termine.
- iii. Après avoir effectué les étapes ci-dessus, l'ensemble d'apprentissage et l'ensemble de test sont avancés d'une observation, et les étapes ci-dessus sont répétées jusqu'à ce que la n ième observation de la série temporelle soit également prise par l'ensemble de test, puis le cycle se termine.

En prenant l'exemple de les réseaux ferrés, le principe de la validation croisée est illustré par le schéma suivant:




Figure 32: Validation croisée à l'aide de prévisions glissantes

b) Méthode de division

- i. Diviser l'ensemble de données en un ensemble d'apprentissage et un ensemble de test.
 - Training Dataset: Utilisé pour entraîner le modèle à utiliser.
 - Test Dataset: Utilisé pour l'évaluation finale.
- ii. Dans ce stage, nous avons utilisé cette approche pour la calibration des données RER en divisant les six derniers mois de l'ensemble de données en un ensemble de test et en utilisant le reste des données comme ensemble d'entraînement pour entraîner le modèle.
- iii. Nous jugeons l'efficacité du modèle en prédisant le résultat à six mois à l'aide du modèle entraîné et en comparant ce résultat aux données de l'ensemble de test pour obtenir l'erreur.




Figure 33: Validation de l'erreur de la méthode de division de l'ensemble d'entraînement de l'ensemble de test

4.3.2 Prétraitement des données

1. Assurer les séries stationnaires.

Stationnaire: le stationnaire est divisé en deux catégories : stationnaire strict et stationnaire large. Le stationnaire strict garantit que toute distribution de dimension finie de la série temporelle est invariante par rapport à une translation dans le temps ; le stationnaire large exige que la structure de covariance soit invariante par rapport à une translation dans le temps, également connue sous le nom de série lisse de moment de second ordre. L'importance du stationnaire permet aux caractéristiques fondamentales de la série chronologique de ne pas changer avec le temps.

ARMA: Dans le modèle ARMA, nous supposons que la série temporelle X_t est liée de manière causale aux perturbations antérieures[37], qu'elles soient internes ou externes, que cette causalité est continue sur la série temporelle et que nous devons supposer que la série est lisse afin d'effectuer une estimation des paramètres à partir des données de la série temporelle, c'est-à-dire que le temps ne doit pas avoir d'effet sur la fonction de distribution de notre processus stochastique.

Test de contrôle: À ce stade, nous avons mis en place une expérience de groupe de contrôle pour identifier le modèle présentant l'erreur la plus faible, c'est-à-dire le meilleur modèle. Pour garantir la qualification des modèles ARMA, nous nous sommes donc assurés que les séries temporelles de tous les modèles étaient stationnaires.

2. Sélection des influences météorologiques pour différents types de trafic.

- Dépistage des facteurs météorologiques
 - Nous avons importé des données météorologiques de sources ouvertes[38]. Comme les informations des stations météorologiques sont enregistrées toutes les trois heures, nous sélectionnons d'abord les facteurs météorologiques dont les valeurs manquantes sont inférieures à 10%, puis nous calculons les valeurs de ces facteurs pour une journée en utilisant la méthode du tableau ci-dessous.

Table 3: Sélection des facteurs météorologiques

Facteurs météorologiques	Méthode de consolidation
tc	mean
per	max
td	mean
dd	mean
u	mean
tend	mean
rafper	max
pmer	mean
ff	mean
pres	mean
vv	mean
ht_neige	max
rr3	sum
n	mean
nbas	mean

* **tc:** Température (°C), **per:** Période de mesure de la rafale, **td:** Point de rosée. **dd:** Direction du vent moyen 10 mn, **u:** Humidité, **tend:** Variation de pression en 3 heures. **rafper:** Rafales sur une période, **pmer:** Pression au niveau mer. **ff:** Vitesse du vent moyen 10 mn, **pres:** Pression station. **vv:** Visibilité horizontale, **ht_neige:** Hauteur totale de la couche de neige, glace, autre au sol. **rr3:** Précipitations dans les 3 dernières heures, **n:** Nebulosité totale, **nbas:** Nebulosité des nuages de l'étage inférieur.

- Interaction entre les facteurs météorologiques
 - Pour éviter de sélectionner des facteurs peu pertinents et donc de gaspiller des ressources informatiques.

- a) Nous identifions comme pertinents les facteurs qui sont liés entre eux à plus de 5%.
 - b) Pour les facteurs pertinents, nous avons sélectionné le plus influent de tous les facteurs pertinents comme facteur externe.
 - c) S'il y a plus de facteurs pertinents, nous choisissons deux paramètres comme facteurs externes pour garantir l'équité.
- Dans le diagramme ci-dessous, nous pouvons déterminer la relation entre deux facteurs en fonction de la couleur, par exemple, le rouge signifie une corrélation de 100%.




Figure 34: Corrélations des facteurs

- Déterminer l'impact des facteurs sur les données
 - Nous utilisons les méthodes `mutual_info_regression`[39] et `RobustScaler`[40] du paquet `sklearn`[41] pour classer la taille de l'influence des facteurs respectivement.
 - Les résultats de la sélection de différents types de facteurs sont présentés dans le tableau ci-dessous [Table. 2].

Table 4: Résultats de la sélection des facteurs météorologiques pour différents types de trafic

Type de transport	Facteurs météorologiques							
METRO	tc	u	nbas	pres	ff	vv	ht_neige	
BUS	tc	u	nbas	pmre	dd	ff	ht_neige	

4.3.3 Tâche1. Correction des données relatives au type de RER

1. Introduction à la méthode.




Figure 35: Diagramme de la correction des données de validation du RER

- Supprimer les données de validation du RER 2018 et 2019, comme [Fig. 35(a)]
- Remplir les données de prévision corrigées, comme [Fig. 35(b)] (La partie rouge indique les données corrigées)

2. Méthode de correction.

- Nous utilisons les trois méthodes suivantes
 - Ratio à partir des validations du métro. [$NB_R = NB_M \times \text{Ratio}$]
 - NB_R : Les données du RER.
 - NB_M : Les données du Métro.
 - Ratio: Rapport entre les données de validation Métro et les données de validation RER.
 - Ratio = $\frac{NB_M}{NB_R}$ pour 2016 et 2017
 - Prévision à l'aide de modèles de séries chronologiques.
 - Combinaison des méthodes 1 et 2 [Pour plus d'informations, voir ci-dessous]
- Lorsque nous appliquons Neuralprophet car nous prenons en compte des facteurs externes, nous utilisons la méthode ii [Méthodologie de prévision 2(d)iv] pour la prédiction.
 - Nous avons utilisé la première méthode (c'est-à-dire le rapport entre le type de métro et le type de RER) pour obtenir une validation approximative du RER pour 2018-2019 et l'avons utilisée comme référence pour nos projections. [c'est-à-dire la troisième méthode]




Figure 36: Diagramme de la méthode 3

- Procédé pour la méthode 3:
 - i. Utiliser la méthode 1 pour produire des résultats révisés pour les données 2018-2019. [Supposé être représenté par la ligne rouge dans le diagramme]
 - ii. Modèle obtenu par entraînement à partir des données de 2015-2017.
 - iii. Utiliser les données du RER 2018-2019 obtenues à l'étape i comme référence pour nos projections.
 - iv. Prédiction des données en utilisant le modèle formé dans l'étape ii [Supposé être représenté par la ligne verte dans le diagramme]
- 3. Comparaison des méthodes.
 - Nous utilisons une méthode de validation croisée, les six mois suivants de l'ensemble de données fractionné étant utilisés comme ensemble de test pour les tests d'erreur et le reste des données comme ensemble d'apprentissage.
 - Avec la méthode deux, nous trouvons que l'erreur de Neuralprophet est plus petite, d'autre part, Triebe et. al.[42] ont montré que Neuralprophet a de meilleures performances que Prophet.
 - Donc nous utilisons le modèle Neuralprophet fusionné avec la méthode un (i.e. méthode trois)

Table 5: Résultats de la sélection des facteurs météorologiques pour différents types de trafic

Nom de la méthode		Indicateurs			
		R2_test	Mean(APE)	Median(APE)	Std(APE)
M1	Ratio à partir des validations du métro	0,93	8,29%	8,87%	4,09%
	Sans_exog*	0,81	15,80%	9,83%	24,17%
M2	Prophet	0,84	15,05%	8,44%*	23,75%
	Avec_exog_1*	0,84	13,11%	8,68%	16,55%
	Avec_exog_2*	0,81	16,58%	7,67%	30,26%
	Sans_exog*	0,81	16,64%	7,79%*	30,37%
M3	NeuralProphet	0,83	12,73%	7,68%	22,48%
	Avec_exog_2*	0,83	12,79%	5,90%*	27,41%
M1+M2		0,83	12,79%	5,90%*	27,41%

* Sans_exog: Pas de variables externes. Avec_exog_1: Variables externes : is_weekend, is_holiday, facteurs météorologiques. Avec_exog_2: Variables externes : jours fériés et vacances segmentés, semaines segmentées, facteurs météorologiques.

* Les meilleurs modèles actuels.

- En comparant les méthodes dans le tableau [Table. 3], nous savons par MAPE que la troisième méthode a la plus petite erreur et selon R2 nous pouvons voir que le modèle s'ajuste bien, donc nous utilisons la troisième méthode pour la prédiction.
- Question: Pourquoi utiliser la médiane (APE) comme référence pour l'évaluation ?
 - Nous pouvons voir sur les graphiques résiduels qu'il existe des valeurs aberrantes dans l'ajustement du modèle, ce qui entraîne une moyenne et une std inexactes.




Figure 37: Graphiques résiduels du modèle ajusté

4. Prévision des données pour 2018-2019.

- Les résultats de la comparaison avant et après correction sont présentés dans [Fig. 38].




Figure 38: Avant et après la correction des données pour le RER

- Tableau de bord des données corrigées.
– Pour TB_FER_1






Figure 39: Comparaison de TB_FER_1 avant et après modification

- * Pour la figure 1, Après correction, il a été constaté qu'avant la fermeture de la quarantaine due à l'épidémie, la tendance vérifiée était logiquement en augmentation d'année en année.
- * Pour la figure 2, Étant donné que les données corrigées du RER ne comportent pas d'informations sur les stations, nous avons supprimé les informations régionales et nous avons constaté que les données du RER sont proches de la moitié du métro.

- Pour TB_FER_2, En raison d'erreurs dans les données du RER 2018 et 2019, nous avons défini les données en 2018 et 2019 pour montrer les informations pour le métro uniquement.
- Pour TB_FER_3
 - * Parce que le type de tram ne compte que T4, qui est une statistique très petite, son taux de variation est imprécis (et est fortement influencé par la cessation d'opérations telles que les grèves), donc l'allusion à la variation du type de tram est supprimée.
 - * Le graphique en barres corrigé est plus logique et nous trouvons des données pour les trains manquants en juin. Après avoir examiné les informations, il a été constaté que la raison de l'absence était la construction de la ligne de train. Par exemple: [43][44]



(a) TB_FER_3, Avant correction



(b) TB_FER_3, Après correction

Figure 40: Comparaison de TB_FER_3 avant et après modification

4.3.4 Tâche2. Impact de la météo et des vacances sur le trafic du métro et du bus

1. À propos du métro

a) Comparaison des modèles (Utilisation des prévisions glissantes)

Table 6: Comparaison des différentes erreurs de modèle pour le métro

Nom de la méthode		Indicateurs d'évaluation				
		Mean(AE)	Std(AE)	mean(R2)_train	R2_test	Mean(APE)
Linear regression	Avec_exog_1	0,13			0,69	25,35%
	Avec_exog_1_1	0,12			0,73	26,03%
	Avec_exog_1_2	0,11			0,78	25,93%
	Avec_exog_2	0,09			0,82	26,16%
Sarimax	Avec_exog_1. p,q,P,Q = 1, 0, 1, 1 p,q,P,Q = 2, 5, 1, 4	0,07	0,12	0,86	0,84	191,08%
		0,08	0,13	0,84	0,81	326,63%
	Avec_exog_2	0,06	0,07	0,94	0,92*	193,67%
Prophet	Sans_exog	0,09	0,12	0,77	0,8	13,76%
	Avec_exog_1	0,08	0,08	0,84	0,88	11,35%
	Avec_exog_2	0,07	0,08	0,86	0,89	10,99%
NeuralProphet	Sans_exog	0,09	0,12	0,77	0,78	14,31%
	Avec_exog_1	0,07	0,11	0,83	0,84	11,90%
	Avec_exog_2	0,09	0,12	0,86	0,79	13,61%
		Median(APE)	Std(APE)	Quant. 5%	Quant.95%	Confidence interval
Linear regression	Avec_exog_1	9,05%				
	Avec_exog_1_1	8,01%				
	Avec_exog_1_2	6,51%				
	Avec_exog_2	4,97%				
Sarimax	Avec_exog_1. p,q,P,Q = 1, 0, 1, 1 p,q,P,Q = 2, 5, 1, 4	4,04%	25,05%	0,43%	28,87%	28,44%
		5,08%	3280,60%	0,37%	27,04%	26,67%
	Avec_exog_2	3,46%*	2805,11%	4,19%	25,08%	20,89%
Prophet	Sans_exog	6,10%	53,88%	0,50%	37,42%	36,92%
	Avec_exog_1	5,88%	48,24%	0,68%	33,94%	33,26%
	Avec_exog_2	4,87%	48,83%	0,48%	32,91%	32,43%
NeuralProphet	Sans_exog	6,26%	54,87%	0,62%	39,85%	39,23%
	Avec_exog_1	4,28%	51,57%	0,35%	34,82%	34,47%
	Avec_exog_2	5,94%	52,68%	0,42%	40,13%	39,71%

* Sans_exog: Pas de variables externes.

Avec_exog_1: Variables externes : is_weekend, is_holiday, facteur météorologiques.

Avec_exog_1_1: Variables externes : is_weekend, jours fériés et vacances segmentés, facteur météorologiques.

Avec_exog_1_2: Variables externes : semaines segmentées, is_holiday, facteur météorologiques.

Avec_exog_2: Variables externes : jours fériés et vacances segmentés, semaines segmentées, facteurs météorologiques.

* Les meilleurs modèles actuels.

- Les données montrent que SARIMAX est le meilleur modèle.
 - Il obtient un R^2 de 0,92, soit le meilleur coefficient de détermination.
 - Il a obtenu un pourcentage d'erreur de 3,46%, le meilleur résultat de tous les modèles.
 - Il a obtenu un R^2 proche à la formation et à la validation, prouvant que le modèle n'était pas surajusté (overfitting).
- Diagramme de diagnostic du meilleur modèle
 - Le diagramme de diagnostic du modèle est présenté ci-dessous




Figure 41: Diagramme de diagnostic du meilleur modèle pour métro

- * Dans le panneau supérieur droit, nous voyons la ligne KDE rouge avec la ligne $N(0,1)$ (où $N(0,1)$ est le signe standard d'une distribution normale avec une moyenne de 0 et un écart-type de 1). Ceci est une bonne indication de la distribution normale des résidus.
- * Le graphique qq en bas à gauche montre que la distribution ordonnée des résidus (points bleus) suit une tendance linéaire en utilisant une distribution normale standard échantillonnée avec $N(0, 1)$. Là encore, il s'agit d'une forte indication de la distribution normale des résidus.
- * Les résidus dans le temps (panneau supérieur gauche) ne présentent pas de saisonnalité évidente et semblent être un bruit blanc. Ceci est confirmé par l'autocorrélation (c'est-à-dire le graphique de corrélation) dans le coin inférieur droit, qui indique que les résidus des séries temporelles ont une faible corrélation avec leurs propres versions décalées.
- Ces observations nous amènent à conclure que notre modèle donne un ajustement satisfaisant qui peut nous aider à comprendre nos séries de données temporelles.
- Ces observations nous amènent à conclure que notre modèle donne un ajustement satisfaisant qui peut nous aider à comprendre nos séries de données temporelles.
- Ensuite, nous examinons le principe des hyperparamètres à travers les diagrammes acf et pacf.




Figure 42: Fonction d'autocorrélation d'une séquence lisse

- Les hyperparamètres optimaux que nous obtenons par force brute (Méthode de traversée) sont: $(p,d,q)(P,D,Q) = (1,0,5)(7,0,2,7)$ [Le processus de recherche est décrit dans la section Recherche de paramètres ci-dessous.]
 - * Termes autorégressifs, différentiels, moyens glissants (p,d,q)
 - * Facteurs saisonniers : autorégressif, différentiel, moyenne mobile, périodique (P,D,Q,s)
- Pour p et q , nous pouvons observer que l'ACF et le PACF traînent la queue, convergeant tous deux avec des coefficients de 0 après le 3e ordre, ce qui implique que les valeurs de p,q devraient toutes deux fluctuer au-dessus et au-dessous de 3.
 - * Tail-dragging : a toujours une valeur non nulle, n'est pas égal à zéro après que k soit supérieur à une constante (ou fluctue aléatoirement autour de 0)
 - * Queues tronquées : queues tronquées d'ordre k qui convergent rapidement vers 0 après une constante k .
 - * Et nos coefficients optimaux sont $p,q = 1,5$, tous deux autour de 3, ce qui est logique.
- Pour P et Q , nous pouvons observer que l'ACF tend vers l'équilibre après deux cycles, tandis que le PACF tend vers l'équilibre après 6 cycles, et le nombre optimal de simulations est $P,Q = 7, 2$, ce qui est logique.
- Nous avons donc choisi le modèle $SARIMAX(1,0,5)(7,0,2,7)$ pour analyser l'impact des facteurs météo et vacances sur les flux de type métro.

b) Analyse des résultats




Figure 43: Impact de la météo et des vacances sur le trafic du métro

Table 7: Résultats sur l'impact des facteurs météorologiques et de vacances sur les flux de passagers de métro

Nom de la variable externe		Pourcentage de l'impact
Vacances	Vacans_noel	-27.17%
	Vacans_hiver	-14.17%
	Vacans_printemps	-10.87%
	Vacans_ete	-25.18%
	Vacans_Toussaint	-6.7%
	Pont_Ascension	-14.14%
Jours fériés	Jour_de_l'an	-42.87%
	Lundi_de_Pâques	-48.81%
	Fête_du_Travail	-43.63%
	Armistice_1945	-41.71%
	Ascension	-48.05%
	Lundi_de_Pentecôte	-44.55%
	Fête_nationale	-12.03%
	Assomption	-42.26%
	Toussaint	-40.42%
	Armistice_1918	-33.32%
	Noël	-37.6%
Semaine	Mardi	8.47%
	Mercredi	7.84%
	Jeudi	9.91%
	Vendredi	8.31%
	Samedi	-30.91%
	Dimanche	-46.54%
Facteurs météorologiques	tc*	-1.78%
	u*	-0.8%
	nbas*	4.29%
	ff*	4.39%
	vv*	-5.87%
	ht_neige*	-11.62%

* Les unités du facteur météorologique [Table. 2] sont indiquées ci-dessous:

tc -> 10 degrés, u: -> 10%, nbas -> 10 octa, ff -> 1 dm/s, vv -> 100 mm, ht_neige -> 1 dm

- Pour le facteur vacances, l'impact le plus important sur le trafic est celui des vacances de Noël, qui entraînera une réduction de 27,17% du trafic.
- En ce qui concerne les jours fériés, c'est le Lundi_de_Pâques et l'Ascension qui ont le plus d'impact sur le trafic de passagers. Le trafic de passagers sera réduit de 48,81% et 48,05% respectivement.
- En ce qui concerne le facteur jour de la semaine, la plus forte baisse de trafic a été enregistrée les jours de dimanche par rapport aux lundi, avec 46,54%.
- Pour les facteurs météorologiques
 - tc: Cela signifie que pour chaque variation de dix degrés de la température, le flux de circulation diminue de 1,78%.
 - u: Cela signifie une variation de 10% de l'humidité et une réduction de 0,8% du flux de circulation.
 - nbas: Cela représente une variation de 10octa de la turbidité des nuages et une augmentation de 4,29% du flux de trafic.
 - ff: Cela représente une variation de 4,39% du trafic pour une augmentation de 1 dm/s de la vitesse du vent.
 - vv: Cela signifie que pour chaque variation de 100 mm de la visibilité horizontale, les flux de trafic seront réduits de 5,87%.

- ht_neige: Cela signifie que pour chaque dm de neige, les flux de trafic sont réduits de 11,62%.

c) **Question:** Pourquoi expérimenter deux hyperparamètres lors d'une modélisation utilisant SARI-MAX ainsi que le premier ensemble de variables extrinsèques ?[pqPQ=1011,pqPQ=2514]

- En effet, dans les trois séries de tests AIC, BIC et HQIC, les meilleurs paramètres de l'AIC et du HQIC étaient les mêmes, mais le BIC a obtenu un ensemble de paramètres différent.
- Pour $p,q,P,Q=1,0,1,1$
 - i. Simple et interprétable
 - ii. 38^{ème} pour HQIC, 26^{ème} pour AIC
- Pour $p,q,P,Q=2,5,1,4$
 - i. Le meilleur pour deux critères
 - ii. Top 20 (17^{ème}) pour BIC (Toujour bon pour tous les critères)
- Bien qu'il se soit avéré que de meilleurs résultats auraient pu être obtenus en utilisant le deuxième ensemble de variables externes, les deux ensembles d'hyperparamètres ont tout de même été testés, ce qui a permis d'augmenter encore la précision de ce test.

2. À propos du bus

a) Comparaison des modèles (Utilisation des prévisions glissantes)

Table 8: Comparaison des différentes erreurs de modèle pour le bus

Nom de la méthode		Indicateurs d'évaluation				
		Mean(AE)	Std(AE)	mean(R ²)_train	R ² _test	Mean(APE)
Linear regression	Avec_exog_1	0,15			0,69	21,99%
	Avec_exog_2	0,11			0,76	17,32%
Sarimax	Avec_exog_2	0,08	0,11	0,92	0,86	12,02%
Prophet	Avec_exog_2	0,11	0,12	0,92	0,81	16,13%
NeuralProphet	Avec_exog_2	0,15	0,16	0,83	0,64	20,84%
		Median(APE)	Std(APE)	Quant. 5%	Quant.95%	Confidence interval
Linear regression	Avec_exog_1	7,62%				
	Avec_exog_2	4,44%*				
Sarimax	Avec_exog_2	4,79%*	29,59%	8,03%	36,59%	28,56%
Prophet	Avec_exog_2	7,29%	32,19%	7,39%	54,77%	47,38%
NeuralProphet	Avec_exog_2	8,71%	35,21%	1,73%	71,16%	69,43%

* Avec_exog_1: Variables externes : is_weekend, is_holiday, facteur météorologiques.

Avec_exog_2: Variables externes : jours fériés et vacances segmentés, semaines segmentées, facteurs météorologiques.

* Les meilleurs modèles actuels.

- En comparant les modèles de régression linéaire, nous avons constaté que, comme pour les données expérimentales du métro, le choix d'une deuxième variable externe donnait des erreurs plus faibles, et donc que la première variable externe n'était plus testée dans les modèles SARIMAX, Prophet et Neuralprophet.
 - Cependant, si le temps et les ressources informatiques le permettent, effectuer le même type de test que le métro peut fournir une plus grande assurance quant à l'exactitude du test.
- En comparant les données d'erreur des différents modèles, nous avons constaté que pour le modèle SARIMAX et le modèle de régression linéaire, les erreurs sont respectivement de 4,44% et 4,97%, ce qui est très proche, et selon R^2 , nous avons constaté que le modèle SARIMAX est le meilleur, donc nous choisissons toujours **le modèle SARIMAX**.
- Pour le modèle Neuralprophet, nous pouvons voir qu'en comparant R^2 au moment de la formation et au moment du test, nous constatons que le modèle est surajusté.

- Et en comparant les erreurs, nous constatons que le modèle a de plus mauvaises erreurs que le modèle traditionnel, nous pouvons conclure que les modèles d'apprentissage profond ne sont pas meilleurs que les modèles traditionnels dans toutes les applications.
- Ensuite, nous examinons le principe des hyperparamètres à travers les diagrammes acf et pacf.




Figure 44: Fonction d'autocorrélation d'une séquence lisse

- Les hyperparamètres optimaux que nous obtenons par force brute sont: $(p,d,q)(P,D,Q) = (1,0,0)(1,0,0,7)$ [Le processus de recherche est décrit dans la section Recherche de paramètres ci-dessous.]
- Nous pouvons voir que le graphique ACF est en queue, tandis que le graphique PACF tronque la queue, par conséquent, $q,Q = 0,0$ ou $1,1$.
- On peut observer que q tend vers zéro au troisième temps, donc q flotte autour de 3, et Q plafonne à 4, donc Q flotte autour de 4.
- Et le nombre optimal de simulations est $p,q,P,Q = 1,0,1,0$, ce qui est logique.
- Nous avons donc choisi le modèle SARIMAX(1,0,0)(1,0,0,7) pour analyser l'impact des facteurs météo et vacances sur les flux de type bus.
- Le diagramme de diagnostic du meilleur modèle est présenté dans [Fig. 45].
 - Dans le panneau supérieur droit, nous voyons la ligne KDE rouge avec la ligne $N(0,1)$ (où $N(0,1)$ est le signe standard d'une distribution normale avec une moyenne de 0 et un écart-type de 1). Ceci est une bonne indication de la distribution normale des résidus.
 - Le graphique qq en bas à gauche montre que la distribution ordonnée des résidus (points bleus) suit une tendance linéaire en utilisant une distribution normale standard échantillonnée avec $N(0, 1)$. Là encore, il s'agit d'une forte indication de la distribution normale des résidus.
 - Les résidus dans le temps (panneau supérieur gauche) ne présentent pas de saisonnalité évidente et semblent être un bruit blanc. Ceci est confirmé par l'autocorrélation (c'est-à-dire le graphique de corrélation) dans le coin inférieur droit, qui indique que les résidus des séries temporelles ont une faible corrélation avec leurs propres versions décalées.




Figure 45: Diagramme de diagnostic du meilleur modèle pour bus

b) Analyse des résultats




Figure 46: Impact de la météo et des vacances sur le trafic du bus

Table 9: Résultats sur l'impact des facteurs météorologiques et de vacances sur les flux de passagers de métro

Nom de la variable externe		Pourcentage de l'impact
Vacances	Vacans_noël	-30.51%
	Vacans_hiver	-13.83%
	Vacans_printemps	-14.08%
	Vacans_été	-29.92%
	Vacans_Toussaint	-13.19%
	Pont_Ascension	0.0%
Jours fériés	Jour_de_l'an	3.9%
	Lundi_de_Pâques	-51.28%
	Fête_du_Travail	-63.31%
	Armistice_1945	-56.35%
	Ascension	-53.55%
	Lundi_de_Pentecôte	-53.34%
	Fête_nationale	-40.93%
	Assomption	-45.93%
	Toussaint	-50.66%
	Armistice_1918	-39.78%
	Noël	-24.02%
Semaine	Mardi	5.27%
	Mercredi	2.8%
	Jeudi	3.36%
	Vendredi	0.89%
	Samedi	-38.0%
	Dimanche	-54.15%
Facteurs météorologiques	tc*	-0.1%
	dd*	0.1%
	ff*	14.0%
	vv*	3.99%
	pmer*	0.42%
	ht_neige*	2.65%

* Les unités du facteur météorologique [Table. 2] sont indiquées ci-dessous:

tc -> 10 degrés, dd: -> 10 degrés, nbas -> 10 octa, ff -> 1 dm/s, vv -> 100 mm, pmer -> 1kpa, ht_neige -> 1 cm

- Pour le facteur vacances, l'impact le plus important sur le trafic est celui des vacances de Noël, qui entraînera une réduction de 30.51% du trafic. D'autre part, les vacances d'été ont aussi un impact important sur le trafic de passagers.
- En ce qui concerne les jours fériés, c'est la fête du travail qui aura le plus d'impact sur le trafic passagers. Le trafic de passagers sera réduit de 63.31%.
- En ce qui concerne le facteur jour de la semaine, la plus forte baisse de trafic a été enregistrée les jours de dimanche par rapport aux lundi, avec 54,15%.
- Pour les facteurs météorologiques
 - tc, dd: Effet négligeable de la température et de la direction du vent sur le débit du bus.
 - pmer: Cela signifie qu'une variation de 1 kpa de la pression au niveau de la mer est associée à une augmentation de 0,42% du bus.
 - ff: Cela représente une variation de 14% du trafic pour une augmentation de 1 dm/s de la vitesse du vent.
 - vv: Cela signifie que pour chaque variation de 100 mm de la visibilité horizontale, les flux de trafic seront réduits de 3,99%.
 - ht_neige: Cela signifie que pour chaque cm de neige, les flux de trafic sont réduits de 2,65%.

3. En Résumé

a) Comparaison des avantages et des inconvénients des modèles

i. Modèles de régression linéaire

- Avantages
 - A. Une approche simple de la modélisation
 - B. Peu de paramètres requis
- Inconvénients
 - A. Les résultats ne sont pas bons
 - B. La dépendance est linéaire
 - C. Pas de passé ou de période

ii. Modèle SARIMAX

- Avantages
 - A. Compte tenu de la dépendance temporelle
 - B. A un caractère cyclique
 - C. Il est simple et facile à comprendre
 - D. Pour les prévisions glissantes, il donne les meilleurs résultats
- Inconvénients
 - A. Les dépendances sont lineaires

iii. Modèle de Prophet

- Avantages
 - A. Une approche simple de la modélisation
 - B. Peu de paramètres requis
- Inconvénients
 - A. Les résultats ne sont pas bons
 - B. La dépendance est linéaire
 - C. Pas de passé ou de période

iv. Modèle de Neuralprophet

- Avantages
 - A. Avec tous les avantages de Prophet
 - B. Une modélisation plus rapide que celle de Prophet
- Inconvénients
 - A. Les termes de tendance sont sujets à des cycles contradictoires, c'est-à-dire que le modèle est sujet à un ajustement excessif.

b) Synthèse

- Comme le montrent les résultats, tant pour les données du métro [Table: 1a] que pour celles du bus [Table: 2a], le modèle SARIMAX peut être utilisé pour mieux ajuster le modèle et obtenir l'erreur la plus faible possible.
- Nous pouvons tirer certaines conclusions sur la base des facteurs qui affectent le flux de passagers:
 - Pour les vacances, ce qui peut entraîner une augmentation des transports publics à vide.
 - Pour la météo, en fonction de la température, de l'humidité, etc., cela peut entraîner des changements dans le taux d'occupation des transports publics

4.3.5 Définition des hyperparamètres et du processus de recherche

1. Trouver les hyperparamètres avec auto-ARIMA

Theorem 1 (Hyperparamètres et paramètres). *les paramètres sont les résultats appris par la machine, les hyperparamètre signifie une valeur spécifiée artificiellement par la machine avant l'apprentissage.*

Table 10: Trouver les hyperparamètres optimaux en utilisant les deux premières méthodes

M & C	Normal			Log(y)			Nelder-Mead		
	AIC	BIC	HQIC	AIC	BIC	HQIC	AIC	BIC	HQIC
Méthode1	(1,0,1)(3,0,1) ²	(1,0,1)(2,0,1)	(1,0,1)(3,0,1) ²	(2,0,3)(2,0,3) ²	(2,0,3)(2,0,1) ²	(2,0,3)(2,0,1) ²	(1,0,0)(4,0,1) ²	(1,0,0)(3,0,1) ⁴	(2,0,0)(3,0,1)
	(1,0,1)(4,0,1)	(2,0,0)(2,0,1)	(2,0,0)(3,0,1) ²	(2,0,3)(1,0,2) ³	(2,0,3)(1,0,2) ³	(2,0,3)(1,0,2) ³	(1,0,0)(3,0,1) ⁴	(2,0,0)(2,0,1)	(1,0,0)(3,0,1) ⁴
	(2,0,0)(3,0,1) ²	(1,0,1)(1,0,1)	(1,0,1)(2,0,1)	(2,0,3)(2,0,3) ²	(1,0,3)(2,0,1) ²	(1,0,3)(2,0,1) ²	(1,0,0)(3,0,1) ⁴	(1,0,0)(3,0,0)	(1,0,0)(4,0,1) ²
Méthode2	(1,0,1)(3,0,1) ⁴	(1,0,1)(2,0,1)	(1,0,1)(3,0,1) ⁴	(2,0,3)(2,0,3) ²	(2,0,3)(2,0,1) ²	(2,0,3)(2,0,1) ²	(1,0,0)(4,0,1) ³	(1,0,0)(3,0,1) ⁶	(2,0,0)(3,0,1)
	(1,0,1)(4,0,1) ²	(2,0,0)(2,0,1)	(2,0,0)(3,0,1) ²	(2,0,3)(1,0,2) ³	(2,0,3)(1,0,2) ³	(2,0,3)(1,0,2) ³	(1,0,0)(3,0,1) ⁶	(2,0,0)(2,0,1)	(1,0,0)(3,0,1) ⁶
	(2,0,0)(3,0,1) ²	(1,0,1)(1,0,1)	(1,0,1)(2,0,1)	(2,0,3)(2,0,3) ²	(1,0,3)(2,0,1) ²	(1,0,3)(2,0,1) ²	(1,0,0)(3,0,1) ⁶	(1,0,0)(3,0,0)	(1,0,0)(4,0,1) ³
	(1,0,1)(3,0,2) ²	(1,0,1)(3,0,1) ⁴	(1,0,1)(4,0,1) ²	(3,0,4)(2,0,3)	(1,0,3)(1,0,2) ²	(1,0,3)(1,0,2) ²	(1,0,0)(3,0,2) ²	(1,0,0)(4,0,1) ³	(1,0,0)(3,0,1) ⁶
	(1,0,1)(3,0,1) ⁴	(1,0,1)(1,0,2)	(1,0,1)(3,0,2) ²	(2,0,4)(2,0,3)	(1,0,2)(2,0,1)	(1,0,2)(2,0,1)	(2,0,0)(4,0,1)	(1,0,0)(3,0,1) ⁶	(1,0,0)(3,0,2) ²

* M&C: Méthodes d'optimisation & Critères de jugement, eg: ² -> Cet ensemble d'hyperparamètres apparaît deux fois.




Figure 47: Anomalies de la valeur résiduelle

EXPLICATION DU PHÉNOMÈNE Récurrence d'un ensemble d'hyperparamètres
C'est logique, parce que l'un a un intercept et l'autre n'en a pas.

Il s'est avéré que le paramètre optimal ne pouvait pas être trouvé car la valeur obtenue était un minimum local[Comme Table Méthode1], donc la méthode suivante a été utilisée pour le résoudre:

- Les trois meilleurs hyperparamètres sont étendus aux cinq meilleurs hyperparamètres.[Comme Table Méthode2]
- On constate que p, q, P, Q sont groupés à 2, 1, 3, 1 respectivement, donc start_p=2, start_q=1 start_P=3, start_Q=1
- Utilisation de la force brute, stepwise = False

Cependant, selon les graphiques résiduels, de nombreuses anomalies résiduelles ont été trouvées, de sorte qu'une tentative a été faite pour trouver à nouveau les hyperparamètres en utilisant la méthode 3.

Theorem 2 (Résidus). *Les résidus d'un modèle statistique ou d'apprentissage automatique sont la différence entre les valeurs observées et prédites des données. Il s'agit de mesures diagnostiques utilisées pour évaluer la qualité d'un modèle. Elles sont également connues sous le nom d'erreurs.*

DÉTERMINATION DE LA DATE DES ANOMALIES RÉSIDUELLES La date à laquelle l'exception a été trouvée est indiquée.

Table 11: Dates où l'erreur dans la valeur simulée est supérieure à 100%

2015		2016		2017		2018	
13/10/2015	Mar	14/03/2016	Lun	06/11/2017	Lun	20/07/2018	Ven
14/10/2015	Mer	15/03/2016	Mar			21/07/2018	Sam
15/10/2015	Jeu						
16/10/2015	Ven	31/03/2016	Jeu				
17/10/2015	Sam						
		11/04/2016	Lun				
23/10/2015	Ven	12/04/2016	Mar				
24/10/2015	Sam						
25/10/2015	Dim	17/09/2016	Sam				
26/10/2015	Lun						
		07/10/2016	Lun				

On a observé que ces jours étaient le plus souvent consécutifs, probablement en raison de l'impact d'activités d'une durée relativement courte sur le nombre réel de validations, comme les grèves[45, 46] ou incident[47].

Cela conduit à des simulations de modèle incorrectes et, d'autre part, les hyperparamètres sont toujours localement optimaux, ce qui conduit à un apprentissage insuffisant.

TROUVER DES HYPERPARAMÈTRES PAR TRAVERSÉE Nous avons donc abandonné la fonction d'adressage automatique et écrit notre propre boucle pour calculer les résultats d'évaluation de chaque traversée afin de trouver le meilleur résultat.

Intervalle approximatif de p, q, P, Q à partir du diagramme ACF, PACF, p, q : converge vers 0 après combien de order, P, Q : converge vers 0 après combien de order.

Algorithm 1 Trouver les hyperparamètres de SARIMAX par traversée

```

for p in range(0,7) do
  for q in range(0,7) do
    for P in range(0,8) do
      for Q in range(0,8) do
        statsmodels.tsa.arima.model.ARIMA(endog=[Nombre de validations],
        exog=[Variables externes], order=(p, o, q), seasonal_order=(P, o, Q, 7))
        if "model_SARIMAX_RF.fit(method='statespace'), Peut être exécuté" then
          "Stocke les valeurs aic, bic et hqic."
        else if "model_SARIMAX_RF.fit(method='innovations_mle', gls_kwargs='max_iter':200), Peut
        être exécuté" then
          "Stocke les valeurs aic, bic et hqic."
        else
          "aic, bic, hqic sont stockés comme des valeurs nulles."
        end if
      end for
    end for
  end for
end for
end for

```

2. Trouver les hyperparamètres de Neuralprophet

- a) NeuralProphet comporte un certain nombre d'hyperparamètres qui doivent être spécifiés par l'utilisateur. S'ils ne sont pas spécifiés, les valeurs par défaut de ces hyperparamètres sont utilisées.
- b) Nous choisissons les deux hyperparamètres les plus influents [comme indiqué ci-dessous]. En théorie, si le temps et les ressources informatiques le permettent, de meilleurs résultats peuvent être obtenus en optimisant tous les hyperparamètres ou en augmentant la plage de recherche des hyperparamètres.

N_LAGS `n_lags` définit si l'AR-Net est activé (si > 0) ou non. Ici, nous choisissons de 1 à 14.

NUM_HIDDEN_LAYER `num_hidden_layers` définit le nombre de couches cachées du FFN utilisé dans le modèle. Cela inclut les FFN pour les AR-Net et les régresseurs retardés. Afin de trouver un compromis entre la complexité de calcul et l'amélioration de la précision, il est recommandé de fixer le nombre de couches cachées entre 0 et 3.

Algorithm 2 Définition des hyperparamètres du modèle neuralprophet

```

for n_lags in range(1, 15) do
  for num_hidden_layer in range(0, 4) do
    m = NeuralProphet(n_lags, num_hidden_layers, weekly_seasonality=True)
    m = m.add_lagged_regressor(Les Variables externes)
    matric = m.fit(Training set, freq='D', validation_df=Test set)
  end for
end for

```

- c) Les hyperparamètres optimaux ont été dérivés comme suit.

Table 12: Top 3 des hyperparamètres les plus recherchés

Classement	Indicateurs d'évaluation			Hyperparamètres	
	SmoothL1Loss*	MAE	RMSE	n_lags	num_hidden_layers
1	0.002551	0.054667	0.087371	10.0	2.0
2	0.003393	0.060131	0.095290	11.0	2.0
3	0.002591	0.060673	0.092204	8.0	1.0

* SmoothL1Loss[48] est une combinaison de L2Loss et de L1Loss, qui présente certains des avantages de L2 Loss et de L1 Loss.

5 PERSPECTIVES ET CONCLUSIONS

5.1 Résumé du stage




Figure 48: Résumé du stage

L'objectif principal de ce stage est d'explorer les données open source fournies par IDFM sur les transports publics à Paris afin de construire un tableau de bord de données pour faciliter l'analyse des données sur les transports parisiens. Ce stage peut être divisé en trois phases.

Dans la première phase du stage, les données ont été explorées et visualisées à l'aide de pandas et de plotly. Au cours de ce processus, j'ai pu :

- Améliorer les compétences en matière de traitement et d'analyse des données **Pandas**.
- Améliorer les capacités de visualisation des données **Plotly**
- Comprendre et appliquer python data streaming **Pickle**.

Dans la deuxième phase du stage, création d'un tableau de bord sur les données de validation pour analyser et comprendre les déplacements en Transport en commun en Île-de-France. Au cours de ce processus, j'ai pu :

- Apprendre à connaître **Django**.
- Apprendre et pratiquer les langages **HTML**, **CSS** et **JAVAScript**.
- Apprendre les principes du logiciel **MATSim**.
- Comprendre et appliquer le système de gestion des versions du code **Git**.

Dans la troisième phase du stage, des modèles de séries chronologiques ont été utilisés pour prévoir et corriger les tableaux de bord de données et pour étudier l'impact des vacances et de la météo sur la fréquentation du métro et des bus. Au cours de ce processus, j'ai pu :

- Apprendre et appliquer **des modèles de séries chronologiques**.
- Consolider les connaissances en matière d'**apprentissage automatique**.

Les parties des résultats de cette expérience qui peuvent encore **être optimisées** sont les suivantes :

- Pour la partie prévision des données RER, on pourrait essayer plus de modèles de séries temporelles pour rechercher de petites erreurs.
- Pour les variables de facteurs externes, seuls les facteurs météorologiques et de vacances ont été pris en compte dans cette expérience, en explorant d'autres facteurs externes qui pourraient théoriquement être utilisés pour réduire davantage les erreurs du modèle existant.

5.2 Réflexions sur le stage

Le temps passe vite et cinq mois se sont écoulés. Ce stage a été une expérience inoubliable pour moi et a été riche en récompenses.

En tant qu'étudiants, nous attendons avec impatience de devenir matures et compétents grâce à une expérience, et c'est peut-être là le sens d'un stage, un baptême pour ceux d'entre nous qui sont sur le point de quitter l'école. J'avais hâte de grandir et de pouvoir parler avec éloquence de mon travail en tenue de soirée. Mais dès que je suis entrée dans le bâtiment, j'ai réalisé que le lieu de travail était très différent du campus.

En fait, il n'est pas difficile de constater que même si nous avons regardé plus de cours en privé et fait plus de préparations, il est toujours facile de se tromper lorsque nous entrons réellement dans le travail et travaillons en profondeur, et les connaissances théoriques que nous prenons comme un sauveur de vie ne peuvent jouer qu'un rôle de guide et de soutien de base. Par conséquent, ce n'est que par le biais du stage que nous pouvons sortir du puits profond des connaissances théoriques et voir la réalité plus large de la façon d'opérer. En même temps, cela m'a aussi fait comprendre que l'écart entre ce que nous pouvons faire et ce que nous pouvons bien faire est énorme, et que sans l'opération et la pratique, tout le reste sera nul.

Ce stage de cinq mois a été court et gratifiant, il m'a permis de rafraîchir mes connaissances et d'améliorer mes capacités en cours de route. Il m'a fait comprendre que l'expérience ne consiste pas à savoir combien de temps on fait quelque chose, mais combien de temps on passe à réfléchir, à optimiser et à perfectionner quelque chose. Ce stage a été un exercice de toutes mes capacités et l'expérience a été très enrichissante.

Enfin, je tiens à remercier encore une fois la délicieuse cantine, le coucher de soleil, le soleil et le parfum des fleurs, mon superviseur Pierre et tous les superviseurs pour leur aide indéfectible. Du printemps à l'automne, le stage a pris fin, mais à partir de cet automne, je vais continuer mon chemin avec les compétences et le caractère que j'ai appris de M. Pierre et de mes superviseurs.

RÉFÉRENCES

- [1] IFPEN. Ifpen-presentation, 2022. [Online; accessed 17-Aug-2022].
- [2] IFPEN. Page-pierre-michel, 2022. [Online; accessed 17-Aug-2022].
- [3] Omnil. Observatoire de la mobilité en Île-de-france, 2022. [Online; accessed 15-June-2022].
- [4] Île-de France Mobilités. Île-de-france mobilités, 2022. [Online; accessed 19-Aug-2022].
- [5] Wikipedia. Plagiarism — Wikipedia, the free encyclopedia, 2004. [Online; accessed 19-Aug-2022].
- [6] Emmanuelle Bonerandi. De la mobilité en géographie, 2004.
- [7] Michel Michel. G. dupuy, les territoires de l'automobile, 1995. *L'Information Géographique*, 61(1):41–41, 1997.
- [8] Michel Lussault and Jacques Levy. Dictionnaire de la géographie et de l'espace des sociétés, 2003.
- [9] Perla Serfaty-Garzon and M Segaud. In dictionnaire critique de l'habitat et du logement. à, 7:2, 2003.
- [10] Omnil. Observatoire de la mobilité en Île-de-france_egt2020, 2022. [Online; accessed 22-Aug-2022].
- [11] RATP. Plan métro à paris et en ile-de-france, 2022. [Online; accessed 18-June-2022].
- [12] The pandas development team. Pandas, 2008. [Online; accessed 24-Aug-2022].
- [13] Manfred Mudelsee. Trend analysis of climate time series: A review of methods. *Earth-science reviews*, 190:310–322, 2019.
- [14] Eric J Topol. High-performance medicine: the convergence of human and artificial intelligence. *Nature medicine*, 25(1):44–56, 2019.
- [15] Lingxue Zhu and Nikolay Laptev. Deep and confident prediction for time series at uber. In *2017 IEEE International Conference on Data Mining Workshops (ICDMW)*, pages 103–110. IEEE, 2017.
- [16] Torben G Andersen, Tim Bollerslev, Peter Christoffersen, and Francis X Diebold. Volatility forecasting, 2005.
- [17] George EP Box, Gwilym M Jenkins, Gregory C Reinsel, and Greta M Ljung. *Time series analysis: forecasting and control*. John Wiley & Sons, 2015.
- [18] Everette S Gardner Jr. Exponential smoothing: The state of the art. *Journal of forecasting*, 4(1):1–28, 1985.
- [19] Andrew C Harvey. Forecasting, structural time series models and the kalman filter. 1990.
- [20] Kyoung-jae Kim. Financial time series forecasting using support vector machines. *Neurocomputing*, 55(1-2):307–319, 2003.
- [21] Antonio S Cofino, Rafael Cano Trueba, Carmen María Sordo, and José Manuel Gutiérrez Llorente. Bayesian networks for probabilistic weather prediction. 2002.
- [22] Weizhong Yan, Hai Qiu, and Ya Xue. Gaussian process for long-term time-series forecasting. In *2009 international joint conference on neural networks*, pages 3420–3427. IEEE, 2009.
- [23] Weizhong Yan. Toward automatic time-series forecasting using neural networks. *IEEE transactions on neural networks and learning systems*, 23(7):1028–1039, 2012.
- [24] Bryan Lim and Stefan Zohren. Time-series forecasting with deep learning: a survey. *Philosophical Transactions of the Royal Society A*, 379(2194):20200209, 2021.
- [25] Yoshua Bengio, Aaron Courville, and Pascal Vincent. Representation learning: A review and new perspectives. *IEEE transactions on pattern analysis and machine intelligence*, 35(8):1798–1828, 2013.

- [26] Sanjay Surendranath Girija. Tensorflow: Large-scale machine learning on heterogeneous distributed systems. *Software available from tensorflow.org*, 39(9), 2016.
- [27] Sean J Taylor and Benjamin Letham. Forecasting at scale. *The American Statistician*, 72(1):37–45, 2018.
- [28] Oskar Triebe, Nikolay Laptev, and Ram Rajagopal. Ar-net: A simple auto-regressive neural network for time-series. *arXiv preprint arXiv:1911.12436*, 2019.
- [29] Oskar Triebe. Neurprophet, 2022. [Online; accessed 16-Aug-2022].
- [30] Wikipedia. Plagiarism — Wikipedia, the free encyclopedia, 2004. [Online; accessed 05-July-2022].
- [31] Cort J Willmott and Kenji Matsuura. Advantages of the mean absolute error (mae) over the root mean square error (rmse) in assessing average model performance. *Climate research*, 30(1):79–82, 2005.
- [32] Jay L Devore. *Probability and Statistics for Engineering and the Sciences*. Cengage learning, 2011.
- [33] Hirotugu Akaike. A new look at the statistical model identification. *IEEE transactions on automatic control*, 19(6):716–723, 1974.
- [34] Gideon Schwarz. Estimating the dimension of a model. *The annals of statistics*, pages 461–464, 1978.
- [35] Scott I Vrieze. Model selection and psychological theory: a discussion of the differences between the akaike information criterion (aic) and the bayesian information criterion (bic). *Psychological methods*, 17(2):228, 2012.
- [36] Hans R. Kunsch. The Jackknife and the Bootstrap for General Stationary Observations. *The Annals of Statistics*, 17(3):1217 – 1241, 1989.
- [37] Spyros Makridakis and Michele Hibon. Arma models and the box-jenkins methodology. *Journal of forecasting*, 16(3):147–163, 1997.
- [38] Opendatasoft. Observation météorologique historiques france (synop), 2022. [Online; accessed 17-Aug-2022].
- [39] scikit-learn 1.1.2. Sklearn.feature_selection.mutual_info_regression, 2022. [Online; accessed 14-Aug-2022].
- [40] scikit-learn 1.1.2. Sklearn.preprocessing.robustscaler, 2022. [Online; accessed 14-Aug-2022].
- [41] scikit-learn 1.1.2. Scikit-learn, 2022. [Online; accessed 14-Aug-2022].
- [42] Oskar Triebe, Hansika Hewamalage, Polina Pilyugina, Nikolay Laptev, Christoph Bergmeir, and Ram Rajagopal. Neuralprophet: Explainable forecasting at scale. *arXiv preprint arXiv:2111.15397*, 2021.
- [43] Île-de France Mobilités. L’antisÈche travaux du 11 au 17 juin 2018, 2022. [Online; accessed 17-Aug-2022].
- [44] Île-de France Mobilités. L’antisÈche travaux du 18 au 24 juin 2018, 2022. [Online; accessed 17-Aug-2022].
- [45] Citoyens. Grève des machinistes au dépôt de bus ratp de thiais, 2022. [Online; accessed 20-June-2022].
- [46] Le Parisien. Préavis de grève, 2022. [Online; accessed 20-June-2022].
- [47] Île-de France Mobilités. Un incident en gare ratp de nanterre prÉfecture et ses consÉquences sur la ligne l, 2022. [Online; accessed 21-June-2022].
- [48] Pyorch.doc. Smooth l1 loss, 2022. [Online; accessed 14-Aug-2022].
- [49] Kay W Axhausen, Andreas Horni, and Kai Nagel. *The multi-agent transport simulation MATSim*. Ubiquity Press, 2016.

-
- [50] Michał Maciejewski, Joschka Bischoff, and Kai Nagel. An assignment-based approach to efficient real-time city-scale taxi dispatching. 2016.
- [51] Benjamin Loeb, Kara M Kockelman, and Jun Liu. Shared autonomous electric vehicle (saev) operations across the austin, texas network with charging infrastructure decisions. *Transportation Research Part C: Emerging Technologies*, 89:222–233, 2018.
- [52] Michał Maciejewski and Joschka Bischoff. Congestion effects of autonomous taxi fleets. 2016.
- [53] Ana T Moreno, Andrzej Michalski, Carlos Llorca, and Rolf Moeckel. Shared autonomous vehicles effect on vehicle-km traveled and average trip duration. *Journal of Advanced Transportation*, 2018, 2018.
- [54] Michele D Simoni, Kara M Kockelman, Krishna M Gurumurthy, and Joschka Bischoff. Congestion pricing in a world of self-driving vehicles: An analysis of different strategies in alternative future scenarios. *Transportation Research Part C: Emerging Technologies*, 98:167–185, 2019.
- [55] Felix Zwick, Nico Kuehnel, Rolf Moeckel, and Kay W Axhausen. Agent-based simulation of city-wide autonomous ride-pooling and the impact on traffic noise. *Transportation Research Part D: Transport and Environment*, 90:102673, 2021.
- [56] Wikipedia. Plagiarism — Wikipedia, the free encyclopedia, 2007. [Online; accessed 09-Aug-2022].
- [57] Blai Bonet, Gábor Loerincs, and Héctor Geffner. A robust and fast action selection mechanism for planning. In *AAAI/IAAI*, pages 714–719, 1997.
- [58] Xiaoliang Ma, Xiaodong Li, Qingfu Zhang, Ke Tang, Zhengping Liang, Weixin Xie, and Zexuan Zhu. A survey on cooperative co-evolutionary algorithms. *IEEE Transactions on Evolutionary Computation*, 23(3):421–441, 2018.

Annexes

A ANNEXE 1.COMPARAISON AVEC MATSIM ET EGT

1. Connaissances de base

a) Introduction à l'utilisation de MATSim

Le projet de logiciel MATSim (Multi-Agent Transport Simulation) a été lancé vers 2006 dans le but de générer des modèles de trafic et de congestion en suivant des voyageurs synthétiques individuels à travers leur programme d'activité quotidien ou hebdomadaire [49]. Maciejewski et. al.[50] évaluent une stratégie efficace de répartition des taxis en temps réel qui résout le problème d'affectation linéaire pour trouver une affectation taxi-demande globalement optimale à chaque époque de décision. Loeb et. al.[51] constatent qu'il semble y avoir une limite à l'amélioration du temps de réponse par la diminution des temps de charge ou l'augmentation de l'autonomie des véhicules. Maciejewski et. al.[52] évaluent l'impact de l'introduction des TA à l'échelle d'une ville sur la congestion du trafic. Une enquête en ligne sur les préférences déclarées a été conçue pour recueillir des données sur la volonté d'utiliser des véhicules autonomes partagés[53]. Simoni et. al[54] étudient leurs effets sur les conditions du réseau d'Austin, au Texas, et sur le bien-être des voyageurs, en utilisant le modèle de simulation à base d'agents MATSim. Zwick et. al[55] appliquent un algorithme de covoiturage établi dans le cadre de simulation MATSim à une flotte autonome desservant près de 2 millions de demandes à Munich.

b) Principe d'utilisation




Figure 49: Le processus de simulation et d'optimisation de MATSim

i. Exigences initiales

L'objectif principal est de simuler le comportement de mobilité de l'individu.

Cette section contient une liste des projets de l'individu pour toute la journée, y compris une liste d'activités (par exemple, le travail, la maison, etc.), des informations sur les déplacements (par exemple, se rendre au travail en voiture, etc.), la durée des déplacements (par exemple, quitter la maison à 7 h 28, quitter le travail à 17 h 45, etc.), des informations sur le réseau routier, des informations sur les véhicules, etc.

Le module de demande initiale décrit le plan quotidien initial de l'individu, mais en pratique, la simulation peut ne pas réaliser entièrement le plan d'activité quotidien initial de l'individu en raison de l'encombrement du réseau routier, etc.

ii. Plan de mise en œuvre

Ce module simule l'exécution du plan d'activité quotidien d'un individu, également appelé

simulation de la mobilité (Mobsim). Au cours de l'exécution d'un plan, les individus influencent les plans d'activité quotidiens des autres en occupant un espace dans un réseau routier virtuel. La congestion du trafic peut se produire lorsqu'un grand nombre de personnes choisissent d'emprunter la même route pendant une certaine période.

En outre, sous le contrôle du module Contrôleur du système de simulation, le module de planification de l'exécution effectue deux tâches principales :

- Premièrement, il affecte des véhicules à chaque individu à l'aide de l'algorithme de Dijkstra[56] intégré à MATSim, garantissant ainsi que différents modes de trafic fonctionnent sur l'ensemble du réseau routier ;
- Deuxièmement, sur la base du plan d'activité quotidien de l'individu, chaque individu est assuré de choisir le mode de transport approprié pour se déplacer et réaliser l'activité correspondante. MobSim génère des fichiers "événements" après et avant chaque étape du cycle MATSim et à chaque itération, enregistrant les activités de tous les individus, y compris leurs plans de voyage à un moment donné.

Une fois cette étape franchie, les résultats de la simulation sont disponibles pour le mode de transport choisi par chaque individu et le flux de trafic transversal d'une section de route. Les scores d'évaluation de tous les plans de déplacement individuels pour chaque itération sont enregistrés dans 'scorestats.txt' et un graphique linéaire est dessiné pour montrer la performance individuelle et moyenne des plans d'activité pour chaque itération.

iii. Classement

Une fois l'exécution de tous les plans individuels terminée, le module note les plans en fonction de leur exécution. Le module de notation peut personnaliser ses fonctions d'utilité en fonction des différents modes de transport, mais on part généralement du principe que la réalisation de l'activité génère une utilité positive, tandis que le processus de déplacement génère une utilité négative. Chaque individu peut accumuler plus de points en choisissant de parcourir des distances plus courtes et en réalisant des activités plus longues.

iv. Reprogrammation

MATSim continue de générer de nouveaux plans d'activités quotidiennes au fur et à mesure des itérations, ce qui signifie que les individus accumulent des plans et en créent de nouveaux qui diffèrent des plans existants au fur et à mesure de la simulation, et qu'ils constituent une sélection de plans au fil du temps.

Le plan d'activité quotidien de chaque individu est ajusté en fonction de son fonctionnement réel, et chaque individu est capable de "mémoriser" un certain nombre de ses propres plans de déplacement (généralement fixé à 5), qui suivent un "mécanisme de sélection de plan"[57], c'est-à-dire que lorsque le nombre d'individus enregistrés Ce processus suit un "mécanisme de sélection des plans", selon lequel lorsque le nombre de plans de voyage enregistrés par un individu dépasse un nombre déterminé, les plans excédentaires sont supprimés.

Au fur et à mesure de l'itération de la simulation, les scores des plans d'activités quotidiennes de tous les individus s'améliorent, et l'utilité et les performances du système de simulation continuent d'être optimisées.

v. Analyse des résultats

Le logiciel MATSim met en œuvre un algorithme coévolutif[58] pour chaque individu dans ce processus. L'exigence initiale est le plan d'activité quotidien du voyageur, qui est exécuté sur plusieurs itérations dans une simulation de scénario jusqu'à ce que la valeur optimale soit atteinte. Le cycle se poursuit pendant plusieurs itérations jusqu'à ce que l'agent ne soit plus en mesure d'améliorer son score, auquel cas on considère qu'il a atteint l'équilibre de l'utilisateur.

c) Description du fonctionnement de Matsim

- Le simulateur Matsim simule les déplacements en voiture, en transport en commun, au vélo et au marche d'une journée 'type' pour une région donnée.
- La simulation commence de minuit (l'heure 00:00) jusqu'à 6:00 du jour d'après. On simule le scénario jusqu'à 6:00 du jour d'après pour les activités ou les déplacements puissent se déterminer entièrement. A la fin du la simulation, on enregistre tous les évènements qui ont eu pendant ces 30 heures.
- A cause des contraintes sur le temps de calcul, on simule souvent une partie de la population totale. Pour le scénario de l'île-de-france, on simule 5% de la population totale qui sont environ 500,000 agents.

d) L'Enquête Globale Transport (2010)[3]

L'Enquête Globale Transport (EGT) a été réalisée entre 2009 et 2011. Elle a été pilotée par le STIF, ancien nom de Île de France Mobilités, en partenariat avec la DRIEA dans le cadre de l'Omnil. Ce sont 18 000 ménages (soit près de 43 000 personnes) qui ont répondu à un questionnaire détaillé sur leurs déplacements.

2. Traitement des données

a) Traitement de la base de données MATSim




Figure 50: Informations sur MATSim

Step 2. Aucune revalidation requise pour l' change

```

df_MATSIM['valid'] = 0
for deplac in df_MATSIM['person_id_person_trip_id'].unique():
    trajets = df_MATSIM[df_MATSIM['person_id_person_trip_id'] == deplac][['TransportMode']].values.tolist()

idx_df = df_MATSIM[df_MATSIM['person_id_person_trip_id'] == deplac].index.values.tolist()
valid = np.zeros(len(trajets))
for i, traj in enumerate(trajets):
    if (traj == 'bus') | (traj == 'tram'):
        valid[i] = 1
        df_MATSIM.loc[df_MATSIM.index == idx_df[i], 'valid'] = 1
    if (traj == 'metro') | (traj == 'RER') | (traj == 'rail') :
        if i == 0:
            valid[i] = 1
            df_MATSIM.loc[df_MATSIM.index == idx_df[i], 'valid'] = 1
        else:
            if not((trajets[i-1] == 'metro') | (trajets[i-1] == 'RER') | (trajets[i-1] == 'rail')):
                valid[i] = 1
                df_MATSIM.loc[df_MATSIM.index == idx_df[i], 'valid'] = 1
  
```

b) Traitement de la base de données EGT




Figure 51: Informations sur EGT

Table 13: Détail des moyens de transport_Transport collectif

Numéro	Type de transport
10	Train de banlieue SNCF(Transilien)
11	RER (Lignes A, B, C, D, E ou Eole)
12	Orly-Val
13	Métro
14	Tramway
15	TVM
16	Autobus Paris RATP
17	Autobus de banlieue RATP
18	Autre autobus de banlieue OPTILE
19	Noctilien
20	Bateau bus – Vogüéo
30	Transport à la demande
31	Transports employeurs
32	Ramassage scolaire
33	Société de service spécialisée dans le transport des handicapés
34	Autres transports privés collectifs
35	Taxi
40	Avion
41	TGV
42	Grande ligne SNCF autre que TGV
43	TER

```

# Step 2. Aucune revalidation requise pour l' change
df_EGT['valid'] = 0
for deplac in df_EGT['Person_deplac'].unique():
    trajets = df_EGT[df_EGT['Person_deplac'] == deplac]['MOYEN'].values.tolist()
    idx_df = df_EGT[df_EGT['Person_deplac'] == deplac].index.values.tolist()
    valid = np.zeros(len(trajets))
    for i, traj in enumerate(trajets):
        if (traj < 10) | (traj > 13): # Autres que les lignes f rres
            valid[i] = 1
  
```

```

df_EGT.loc[df_EGT.index == idx_df[i], 'valid'] = 1
if (traj == 10) | (traj == 11) | (traj == 12) | (traj == 13):
    if i == 0:
        valid[i] = 1
        df_EGT.loc[df_EGT.index == idx_df[i], 'valid'] = 1
    else:
        if not ((trajets[i-1] == 10) | (trajets[i-1] == 11) | (trajets[i-1] == 12
                                                                ) | (trajets[i-
                                                                1] == 13)):
            valid[i] = 1
            df_EGT.loc[df_EGT.index == idx_df[i], 'valid'] = 1

```

3. Analyse des résultats

Table 14: Comparaison des données

Classification		EGT	IDFM	MATSim
Par Type	Ferré	✓	✓	✓
	Surface	✓	×	✓
Par Arrêt		×	✓	✓
Par Zone	Ferré	✓	✓	✓
	Surface	×	✓	✓

a) Comparaison par ligne et par station (MATSim VS IDFM)




Figure 52: Comparaison des valeurs matsim et mesurées_Ferré (>10k)

- La plupart des valeurs mesurées sont supérieures aux valeurs simulées. Nous constatons que les arrêts présentant des écarts importants sont toutes des stations d'échange, j'en déduis donc que la différence de chiffres s'explique par les raisons suivantes.
- Pour les valeurs mesurées beaucoup plus grandes que les valeurs matsim
 - Le modèle prédit étant basé sur seulement 5% de la population, le petit échantillon entraîne des erreurs.
 - Le résultat prédit est basé sur 2010 mais la première valeur mesurée est 2015, ce qui entraîne une erreur.
- Pour les valeurs matsim beaucoup plus grandes que les valeurs mesurées.

- Tickets magnétiques
- Non validation
- Fraudeurs
- [!] les données de sortie et de correspondances ne sont pas comptabilisées




Figure 53: Comparaison des valeurs matsim et mesurées_Surface_Bus (>10k)

- Pour les valeurs mesurées beaucoup plus grandes que les valeurs matsim
 - Pour d'autres raisons, comme l'itinéraire 208S, parce qu'il n'a pas ouvert en 2010 (aucune information exacte trouvée sur internet, devinette) ou parce qu'aucune des personnes interrogées ne l'a pris.
- Pour les valeurs matsim beaucoup plus grandes que les valeurs mesurées.
 - Les principales raisons sont les mêmes que pour le réseau ferroviaire




Figure 54: Comparaison des valeurs matsim et mesurées_Surface_Tram (>10k)

- Presque exact, mais on peut voir que les valeurs mesurées sont biaisées dans l'écart de 0.2-0.4 (devrait être moins), les principales raisons sont les mêmes que pour le réseau ferroviaire
- b) Comparaison par type, zone et trajet (MATSim VS EGT VS IDFM)

A. Par type

A1) Étapes

i. NB_EGT

- Importation de données EGT
- Filtrer les types par columns = 'moyen', $14 \leq \text{moyen} \leq 34$

ii. NB_MATSim


- Importation de données MATSim
- Filtrer les types

A2) Résultat


- Bus, Tram, Train: $\text{NB_EGT} < \text{NB_MATSim}$
- Métro: $\text{NB_EGT} > \text{NB_MATSim}$
- RER: $\text{NB_EGT} \approx \text{NB_MATSim}$

A3) Analyse

Les simulations montrent plus de trajets en bus, mais l'EGT compte plus de trajets en METRO, par exemple sur des trajets plus courts, et les gens préfèrent prendre le métro plutôt que le bus, même si le bus est plus proche en ligne droite, ce résultat est réaliste.



(a) Comparer par type



(b) Comparer par type_Fer

Figure 55: Résultats de MATSim, EGT et IDFM par type

B. Par zone

B1) Étapes

- i. Importer les Informations sur la zone
- ii. NB_IDFM
 - A. Importation de données IDFM
 - B. NB_VAL additionnées par JOUR (pour combiner différentes cartes de validation)
 - C. Importation de données de Type de date(JOHV)
 - D. Tirer JOHV(Parce que EGT et Matsim sont tous deux des jours de travail)
 - E. Obtenir des données quotidiennes moyennes
 - F. Les données de 2015 ont été extraites pour rapprocher.
 - G. Ajouter les arrondissements et trouver la somme de chaque zone
- iii. NB_EGT
 - A. Importation de données EGT par déplacement et par trajet
 - B. Combiner les EGT pour obtenir le Zone pour chaque trajet.(Par ID_Carré)
 - C. Filtrage des types de transport commun
 - D. Reformulation des zones non parisiennes en zones extérieures
- iv. NB_MATSim
 - A. Importation de données MATSim
 - B. Assurer les stations simulées sont en IDFM (Par ID_LDA)
 - C. Ajouter les arrondissements et trouver la somme de chaque zone


B2) Résultat

- Département 75: NB_MATSim < NB_EGT et NB_IDFM
- D'autre département: NB_MATSim > NB_EGT et NB_IDFM

B3) Analyse

À l'exception de la zone 75, où les valeurs simulées par MATSim sont supérieures aux valeurs de l'EGT et de la IDFM, toutes les autres zones sont inférieures à la valeur de l'MATSim, nous combinons cela avec la comparaison ci-dessus des différents types et ce résultat est considéré comme possible.

EX: les gens prendront plus le métro que le bus dans la zone 75.



(a) Comparer par zone



(b) Comparer par trajet

Figure 56: Résultats de MATSim, EGT et IDFM par zone et trajet

C. Par trajet

C1) Étapes

i. NB_RATP

- Importation de données IDFM
- NB_VAL additionnées par JOUR (pour combiner différentes cartes de validation)
- Importation de données de Type de date (JOHV)
- Tirer JOHV (Parce que EGT et Matsim sont tous deux des jours de travail)
- Obtenir des données quotidiennes moyennes
- Les données de 2015 ont été extraites pour rapprocher.

ii. NB_EGT

- Importation de données EGT
- Supposons que chaque trajet soit une validation
- Extraction séparée des lignes surface et ferré

iii. NB_MATSim

- Importation de données MATSim
- Extraction des types de lignes souterraines et surface
- lignes souterraines: ignorer le type de tram car il n'a que le T4.

C2) Résultat

- Réseaux ferré: $NB_RATP \approx NB_MATSim < NB_EGT$
- Réseaux surface: $NB_RATP \approx NB_MATSim > NB_EGT$

C3) Analyse

i. Réseaux Ferré: $NB_EGT > NB_RATP$

- Avec la comparaison entre les régions ci-dessus, on peut déduire que
- Les deux sont presque égaux, sauf dans la province 75, car les données de l'EGT sont de 2010 et celles de la IDFM de 2015. L'examen des données suggère que la diminution du nombre de validations dans la province 75 est due à l'ouverture de nouveaux trams ou bus entre 2010 et 2015.
- Pour l'EGT, de nombreux travailleurs de province (eg:44) sont comptabilisés, alors que la IDFM ne le fait pas, ce qui entraîne des erreurs.

ii. Réseaux Surface: $NB_EGT < NB_RATP$

- Importation de données MATSim

B. Comme mentionné ci-dessus, l'ouverture de nouvelles lignes de tramway et de bus entre 2010 et 2015 a entraîné la création de changements

4. En conclusion

- L'EGT sur représente les trajets dans Paris ce qui augmente la part de déplacements dans le réseau ferré
- MATSim sur représente les trajets hors de Paris mais la ratio réseau/ferré est bon

B ANNEXE 2.ABRÉVIATIONS DE MOTS

1. IDFM[4] - Île-de-France Mobilités
2. RATP[11] - La Régie autonome des transports parisiens